

Quantum Information

Appunti del corso

*Giuseppe Scordo,
Stefano Mavilla,
Damiano Trovato*

Anno Accademico 2025/26

Indice

I	Teoria dell'Informazione Classica	4
1	Prima comunicazione su canale rumoroso	5
1.1	Come possiamo garantire una comunicazione perfetta in un canale imperfetto e rumoroso?	5
1.2	Canale Binario Simmetrico	5
1.2.1	Soluzioni alla corruzione di bit in un canale di comunicazione	5
1.3	Tecniche di Correzione degli errori in un Canale Binario Simmetrico	6
1.3.1	Codici di Ripetizione	6
1.3.2	Codici a Blocco - Hamming (7,4)	7
2	Fondamenti di probabilità	9
2.1	Variabili aleatorie	9
2.1.1	Teoremi su Variabili Aleatorie	9
2.2	Valore Atteso e Varianza	11
3	Entropia e Informazione di Shannon	14
3.1	Informazione di Shannon	14
3.2	Entropia di una variabile aleatoria	14
3.2.1	Proprietà dell'entropia	14
3.2.2	Regola della Catena per l'entropia	15
3.3	Entropia relativa	17
3.3.1	Funzioni convesse e disuguaglianza di Jensen	17
3.3.2	Entropia Relativa (o Divergenza di Kullback-Leibler)	18
3.3.3	Entropia massima	18
3.3.4	Mutua Informazione	19
3.3.5	Proprietà della Mutua Informazione	19
4	Teorema del Codice Sorgente e Compressione	21
4.1	Massimizzare l'informazione di una variabile aleatoria	21
4.2	Introduzione alla compressione	23
4.3	Compressione Lossy	23
4.3.1	Strumenti per la compressione lossy	24
4.3.2	Teorema del Codice Sorgente di Shannon	25
4.4	Compressione lossless	26
4.4.1	Codici Simbolici	26
4.4.2	Codici Prefix-free	27
4.4.3	Disuguaglianza di Kraft	29
4.4.4	Quanto possiamo comprimere una sorgente?	30
4.4.5	Codifica di Huffman	32
5	Comunicazione su canali Rumorosi	33
5.1	Canali Rumorosi	33
5.1.1	Esempi di canali rumorosi	33
5.1.2	Teorema del Codice di un Canale Rumoroso	36
5.1.3	Teorema di Shannon per canali rumorosi	38
II	Informazione Quantistica	39
6	Fondamenti di algebra lineare	40

6.1	Spazio di Hilbert e prodotto scalare	40
6.1.1	Disuguaglianza di Schwartz	41
6.2	Mappe lineari e matrici	41
6.2.1	Traccia	41
6.2.2	Autovettori e autovalori	41
6.2.3	Matrice trasposta coniugata (o aggiunta, o dagger)	41
6.2.4	Operatori Hermitiani	42
6.2.5	Teorema Spettrale	42
6.2.6	Operatori Positivi	42
6.2.7	Prodotti tensoriali	44
6.3	Stati Quantistici	45
6.3.1	Spazi di Hilbert	45
6.3.2	Stati Quantistici	45
6.3.3	Stati Puri	46
6.3.4	Stati quantistici generici	46
6.4	Qubit e Sfera di Bloch	47
6.5	Misurazioni	48
6.5.1	Misure rispetto a una base e misure proiettive	49
6.5.2	Misurazione di qubit	49
6.6	Sistemi quantistici multipli	50
6.7	Traccia Parziale	51
7	Quantum information processing	52
7.1	Quantum information processing	52
7.1.1	Evoluzione temporale	52
7.2	Operazioni sugli stati	52
7.2.1	Superoperatori e proprietà	52
7.2.2	Mappe positive	53
7.3	Canali quantistici	53

Introduzione al Corso

Quantum information è un corso sulla teoria dell'informazione che si compone di 2 parti

- 3 CFU di Introduzione alla **Teoria dell'Informazione Classica**
- 3 CFU di Introduzione alla **Teoria dell'Informazione Quantistica**

Cos'è la Teoria dell'Informazione?

Fino a che punto possiamo comprimere i dati?

Qual'è il miglior tasso di trasmissione possibile?

- **Teoria classica dell'informazione**

Ci chiediamo cosa sia l'informazione e come renderla affidabile su canali inaffidabili. Vediamo in breve cenni di teoria dell'informazione di Shannon:

- È possibile inviare informazione con probabilità di errore ε , se il tasso di comunicazione è minore della capacità del canale
- Ogni segnale ha complessità intrinseca (*entropia*) oltre al quale non può essere compreso
- Se l'entropia della sorgente è minore della capacità di canale, una comunicazione (asintoticamente) priva di errori può avvenire

- **Teoria dell'informazione quantistica**

A differenza del caso precedente utilizziamo i qubit. Quello che fa davvero la differenza sono i *termini di coerenza*, usando le matrici di densità. Un'altra differenza è la presenza dell'**entanglement**. Studieremo come misurare l'entropia di uno stato quantistico (Entropia di Von Neumann).

Vedremo le seguenti misure: Capacità classica, quantistica e quantistica assistita (con entanglement).

Parte I

Teoria dell'Informazione Classica

Capitolo 1

Prima comunicazione su canale rumoroso

1.1 Come possiamo garantire una comunicazione perfetta in un canale imperfetto e rumoroso?

Nella trasmissione di informazione, come stringhe di bit, in un canale di comunicazione imperfetto, esiste una probabilità che al ricevente del messaggio **non arrivi lo stesso messaggio** inviato dal mittente.


Esempi di canali di comunicazione variano dai cavi di una linea telefonica analogica ai dischi rigidi di un moderno PC, fino alle cellule riproduttive.

1.2 Canale Binario Simmetrico

Nel modello di comunicazione conosciuto come **Canale Binario Simmetrico** viene trasmesso dal mittente una stringa di bit.

Ogni bit x che verrà trasmesso al ricevente può essere corrotto con probabilità f (con $0 \leq f \leq 1$) o arrivare correttamente con probabilità $1 - f$.

Indichiamo inoltre ogni bit ricevuto come y .



$$P(y = 0|x = 0) = 1 - f; \quad P(y = 0|x = 1) = f;$$

$$P(y = 1|x = 0) = f; \quad P(y = 1|x = 1) = 1 - f;$$

1.2.1 Soluzioni alla corruzione di bit in un canale di comunicazione

Esistono in letteratura due approcci per mitigare la creazione di errori in un canale di comunicazione, la soluzione **fisica** e quella **logica**.

Soluzione fisica


La soluzione fisica consiste nel migliorare le caratteristiche fisiche del canale per ridurre la probabilità di errore. Tipicamente le modifiche ad un'infrastruttura fisica ne aumentano i costi.

Soluzione sistemica

La Teoria dell'Informazione e la Teoria dei Codici offrono un approccio diverso. Accettando di comunicare in un canale rumoroso, possiamo **trovare** e **correggere** gli errori introdotti da quest'ultimo.

Aggiungendo un *encoder* prima del canale, possiamo codificare il **messaggio sorgente** s nel messaggio **trasmesso** t , aggiungendo ad esso della **ridondanza**.

Il canale **corrode** il messaggio t in un messaggio r che, arrivato alla fine del canale, verrà decodificato da un *decoder*, che userà la ridondanza per ricostruire il messaggio s .



Ma come possiamo aggiungere ridondanza ad un messaggio? E come possiamo **trovare** e **correggere** errori in un messaggio?

1.3 Tecniche di Correzione degli errori in un Canale Binario Simmetrico

Prima di addentrarci sulle tecniche di Error-Correction in un canale di comunicazione, è importante definire il **Tasso di Trasmissione**, ovvero:

Il rapporto tra i bit che vogliamo inviare e quelli effettivamente codificati.

1.3.1 Codici di Ripetizione

Un'idea semplice per aggiungere ridondanza consiste nel **ripetere ogni bit** del messaggio s per n volte. Scegliendo n dispari, il decoder correggerà il messaggio r scegliendo il bit che compare più frequentemente in ogni sequenza di n bit.

Ad esempio, se ripetessimo ogni bit 3 volte, avremmo una codifica R_3 , quindi per ogni 3 bit sceglieremmo quello che compare almeno 2 volte.

Esempio di Error-Correction con Codici di Ripetizione

Immaginiamo di voler trasmettere il messaggio s : 0110 e ipotizziamo che $f = 0.1$. Allora con probabilità $1 - f = 0.9$ il bit sarà corretto.

Utilizziamo una codifica R_3 per codificare il messaggio s nel messaggio t :

$$0 \rightarrow 000 \quad 1 \rightarrow 111 \quad 1 \rightarrow 111 \quad 0 \rightarrow 000$$

Supponiamo che nel canale il messaggio t sia stato corrotto nel messaggio r :

$$010 \rightarrow 0 \quad 101 \rightarrow 1 \quad 111 \rightarrow 1 \quad 100 \rightarrow 0$$

Nell'esempio fatto, questo semplice algoritmo ha corretto r nel messaggio s originale. Tuttavia i **Codici di Ripetizione** presentano due grossi limiti:

1. Un Tasso di Trasmissione **molto basso**, in quanto con una codifica R_n , il bitrate è di soli $\frac{1}{n}$ bit.
2. Con una cattiva distribuzione degli errori, l'algoritmo potrebbe non riuscire a correggere correttamente r , decodificando un $s' \neq s$. Si potrebbe aumentare la ridondanza per evitare questo scenario, ma la prima limitazione avrebbe ancora più effetto.

La **probabilità** di ottenere una decodifica $s' \neq s$ in una codifica R_3 diventa:

$$P[E_3] = \sum_{i=2}^3 \binom{3}{i} f^i (1-f)^{3-i} = \binom{3}{2} f^2 (1-f) + f^3 = 3f^2 - 2f^3 = O(f^2)$$

con $0 \leq f \leq 1$, quindi $f^2 > f^3$.

Se volessimo ridurre la probabilità di ottenere una decodifica $s' \neq s$ potremmo passare ad una codifica R_5 . Notiamo che questa funzione vale per questo specifico canale **senza perdita** di bit.

In R_5 abbiamo un tasso di perdita:

$$P[E_5] = \sum_{i=3}^5 \binom{5}{i} f^i (1-f)^{5-i} = \binom{5}{3} f^3 (1-f)^2 + \binom{5}{4} f^4 (1-f) + f^5$$

$$P[E_5] = 10f^3(1-f)^2 + 5f^4(1-f) + f^5 = O(f^3)$$

Se volessimo fare lo stesso calcolo per una decodifica R_N avremmo:

$$P[E_N] = \sum_{i=\frac{N+1}{2}}^N \binom{N}{i} f^i (1-f)^{N-i} = O(f^{\frac{N+1}{2}})$$

Notiamo che la **crescita è lineare** e che dovremmo usare troppo spazio per tassi d'errore tendenti allo zero.

Variazione con doppia codifica

Supponiamo di codificare la stessa stringa s nella codifica R_9 . Calcolando la probabilità di ottenere una decodifica $s \neq s'$ otterremmo $P[E_9] = O(f^6)$.

Sfruttando una variante dei Codici di Ripetizione con una doppia codifica, codificando R_9 come R_3^2 , cioè codificando due volte in R_3 .

Come esempio prendiamo il messaggio s : 1101 che con questa codifica diventa:

$$1 \rightarrow 111 \quad 1 \rightarrow 111 \quad 0 \rightarrow 000 \quad 1 \rightarrow 111$$

e successivamente:

$$111 \rightarrow 111111111 \quad 111 \rightarrow 111111111 \quad 000 \rightarrow 000000000 \quad 111 \rightarrow 111111111$$

Otteniamo:

$$P[E_{R_3^2}] = \sum_{i=2}^3 \binom{3}{i} P_{2R_3}^i (1 - P_{2R_3})^{3-i} \approx O(f^4)$$


che risulta **peggiore** dell'algoritmo classico, quindi paghiamo lo spazio con l'errore.

1.3.2 Codici a Blocco - Hamming (7,4)

Possiamo ottenere trasmettere messaggi s con una bassa probabilità di errore e con un tasso di trasmissione accettabile? Sì, tramite i codici a **Blocchi**.

Un codice a blocco è una **regola** per convertire una sequenza di bit sorgente s di lunghezza K in una sequenza t di lunghezza N , con $N > K$. Gli extra bit $N - K$ sono funzioni lineari degli originali K bit e sono chiamati **bit di parità**.

Un esempio di codice a blocco lineare è il Codice di Hamming (7,4) che trasmette $N = 7$ bit per ogni $K = 4$ bit sorgente. I quattro bit di informazione che vogliamo trasmettere sono indicati come s_1, s_2, s_3, s_4 mentre i bit di parità sono indicati con t_1, t_2, t_3 , scelti affinché:



$$s_1 + s_2 + s_3 + t_1 = 0 \pmod{2}$$

$$s_2 + s_3 + s_4 + t_2 = 0 \pmod{2}$$

$$s_1 + s_3 + s_4 + t_3 = 0 \pmod{2}$$

Il tasso di trasmissione è $\frac{4}{7}$, **migliore** rispetto a quello dei Codici di Ripetizione.

Esempio di Error-Correction con Hamming (7,4)

Trasmettiamo nuovamente il messaggio s : 1101. Calcolando i bit di parità, otteniamo:




Supponiamo che adesso il secondo bit del messaggio t venga corrotto durante la trasmissione nel canale e che diventi il messaggio r : 1001000. Una volta che arriva al decoder, quest'ultimo è in grado di **individuare e correggere l'errore**, in quanto rileva una somma dispari.




Sindrome della decodifica dei Codici di Hamming

Supponiamo ancora una volta di voler trasmettere il messaggio s : 1101 che viene codificato nel messaggio t : 1101000. Questa volta tuttavia si corrompono i bit s_2 ed s_3 e al decoder arriva il messaggio r : 1011000.



Il decoder procederà al rilevamento e alla correzione degli errori. Il risultato della decodifica è il seguente messaggio s' : 1011001, diverso da s .



Ebbene, i codici di Hamming (7,4) **falliscono** nella correzione di messaggi con **almeno due errori**. Sia E_H l'evento che i bit vengano inviati con errori. Allora la probabilità di averne 2 è:

$$P[E_H] = \sum_{i=2}^7 \binom{7}{i} f^i (1-f)^{7-i} = O(f^2)$$

uguale a quella della codifica R_3 , ma con un tasso di trasmissione molto più elevato.

Se vogliamo un tasso d'errore alto sembrerebbe che anche il bitrate debba esserlo. Shannon ci dice che possiamo avere un tasso d'errore basso e un bitrate consistentemente diverso da 0.

Capitolo 2

Fondamenti di probabilità

2.1 Variabili aleatorie

Una **variabile aleatoria** (V.A.) è una tripla (x, A_x, P_x) , dove il risultato x è il valore di una variabile casuale di un insieme di possibili valori $A_x = \{a_0, a_1, \dots, a_{n-1}\}$, ognuno con probabilità $P_x = \{p_0, p_1, \dots, p_{n-1}\}$. Sulla probabilità, valgono i seguenti assiomi:

1. **Non negatività:** Dato un evento E allora $P(E) \geq 0$
2. **Additività:** Siano A, B 2 V.A. indipendenti, allora $P[A \cup B] = P[A] + P[B]$
3. **Normalizzazione:** Sia E l'evento certo, $P[E] = 1$

Da questi assiomi possiamo dimostrare tutti i teoremi sulle probabilità. Possiamo ad esempio dimostrare la probabilità dell'evento impossibile I .

$$P[E] = P[E \cup I] = P[E] + P[I] = 1 + P[I] \Rightarrow P[I] = P[E] - 1 = 0$$

Da ora in poi useremo la notazione: $P[A, B] = P[A \cap B] = P[A \wedge B]$

2.1.1 Teoremi su Variabili Aleatorie

Date 2 variabili aleatorie X, Y con supporti A_x, A_y valgono i seguenti teoremi:

- **Teorema della Probabilità Totale:**

$$P[X = x_i] = \sum_{y \in A_y} P[X = x_i \wedge Y = y_i]$$

- **Probabilità Marginale:** Possiamo ottenere $P(x)$ da $P(x, y)$ tramite una sommatoria:

$$P(x = a_i) \equiv \sum_{y \in A_y} P(x = a_i, y) \Rightarrow P(y) = \sum_{x \in A_x} P(x, y)$$

- **Probabilità condizionata:**

$$P[X|Y] = \frac{P[X \wedge Y]}{P[Y]}$$

da cui segue:

$$P[X = x \wedge Y = y] = P[X = x|Y = y]P[Y = y]$$

- **Teorema di Bayes:**

$$P[X|Y] = \frac{P[Y|X]P[X]}{P[Y]}$$

Esempio N.1 - Meccanico

Alice porta la sua auto dal meccanico. Il meccanico, Bob, dopo aver effettuato un test computerizzato, sostiene che un pezzo molto costoso debba essere sostituito. Sia a la variabile aleatoria che indica lo stato effettivo del pezzo ($a=1$ il pezzo è guasto, $a=0$ il pezzo non è guasto). Si supponga di sapere inoltre che:

1. Il test fatto da Bob ha un'affidabilità del 95%. Nel 95% dei casi in cui il pezzo è rotto allora la risposta fornita è "il pezzo è rotto". Nel 5% dei casi in cui il pezzo non è rotto allora la risposta fornita è "il pezzo non è rotto";
2. Solo l'1% delle vetture (in condizioni analoghe a quella di Alice) ha avuto problemi con il pezzo in questione.

Qual è la probabilità che il pezzo sia effettivamente guasto?

Indichiamo con a la variabile aleatoria che ci dà lo **stato effettivo del pezzo**:

1. Con $a = 1$ il pezzo è guasto, dove $Pr[a = 1] = \frac{1}{100}$
2. Con $a = 0$ il pezzo **non** è guasto, dove $Pr[a = 0] = \frac{99}{100}$

e con b la V.A. che ci dà l'**esito del test**:

1. Con $b = 1$ il test dice "Rotto".
2. Con $b = 0$ il test dice "OK".

Sappiamo inoltre che:

$$\begin{aligned} \bullet P[b = 1|a = 1] &= \frac{95}{100} & \Rightarrow & P[b = 0|a = 1] = \frac{5}{100} \\ \bullet P[b = 0|a = 0] &= \frac{99}{100} & \Rightarrow & P[b = 1|a = 0] = \frac{1}{100} \end{aligned}$$

Per trovare la probabilità che il pezzo sia effettivamente guasto dobbiamo trovare:

$$P[a = 1|b = 1] = \frac{P[a = 1 \wedge b = 1]}{P[b = 1]}$$

Per prima cosa troviamo $P[a = 1 \wedge b = 1]$ che sappiamo è uguale a:

$$P[b = 1|a = 1] \cdot P[a = 1] = \frac{95}{100} \cdot \frac{1}{100}$$

Successivamente troviamo $P[b = 1]$ che sappiamo è uguale a:

$$P[b = 1 \wedge a = 1] + P[b = 1 \wedge a = 0]$$

Possiamo ricavare $P[b = 1 \wedge a = 0]$, essendo uguale a:

$$P[b = 1|a = 0] \cdot P[a = 0] = \frac{1}{100} \cdot \frac{99}{100}$$

Riscriviamo il tutto e ricaviamo $P[a = 1|b = 1]$:

$$P[a = 1|b = 1] = \frac{P[a = 1 \wedge b = 1]}{P[b = 1]} = \frac{\frac{95}{100} \cdot \frac{1}{100}}{\frac{95}{100} \cdot \frac{1}{100} + \frac{1}{100} \cdot \frac{99}{100}} = \frac{95}{95 + 99} = 0,16$$

2.2 Valore Atteso e Varianza

Il **Valore atteso** $E[X]$ rappresenta la nostra aspettativa sul valore di una variabile aleatoria.

$$E[X] = \sum_{x \in A_x} xP[X = x] \quad (2.1)$$

Proprietà del Valore Atteso:

- $E[X, Y] = E[X] + E[Y]$ – Dimostrazione:

$$\begin{aligned} E[X, Y] &= \sum_x \sum_y (x + y)P(x \wedge y) = \\ &= \sum_x \sum_y (xP(x \wedge y) + yP(x \wedge y)) = \\ &= \sum_x x \sum_y P(x, y) + \sum_y y \sum_x P(x, y) = \\ &= \sum_x xP(x) + \sum_y yP(y) = E[X] + E[Y] \end{aligned}$$

- $E[cX] = cE[x]$ e $E[X + c] = E[X] + c$
- Supponendo X, Y indipendenti $E[XY] = E[X]E[Y]$ – Dimostrazione:

$$\begin{aligned} E[XY] &= \sum_{x,y} xyP(x \wedge y) = \sum_x \sum_y xyP(X)P(Y) = \\ &= \sum_x \sum_y xP(x)yP(y) = \sum_x xP(X) \sum_y yP(Y) = E[X]E[Y] \end{aligned}$$

La **Varianza** rappresenta la dispersione dei valori:

$$Var(X) = E[(X - E[X])^2]$$

Analogamente:

$$E[(X - E[X])^2] = E(X^2 + E[X]^2 - 2E[X]) = E[X^2] + E[X]^2 - 2E[X]E[X] = E[X^2] - E[X]^2$$

Esempio N.2 - Lotterie

Consideriamo due possibili esempi di lotteria. Un'estrazione nella lotteria L_1 può risultare in:

- Una perdita di 100 euro con probabilità $P = \frac{1}{4}$
- Una perdita di 200 euro con probabilità $P = \frac{1}{4}$
- Una vincita di 250 euro con probabilità $P = \frac{1}{2}$

Mentre in una lotteria L_2 ogni estrazione risulta in una vincita di 50 euro.

Calcoliamo il **valore atteso** di entrambe le lotterie L_1 ed L_2 .

$$E[L_1] = \frac{1}{4} \cdot (-100) + \frac{1}{4} \cdot (-200) + \frac{1}{2} \cdot (250) = -\frac{100}{4} - \frac{200}{4} + \frac{250}{2} = -25 - 50 + 125 = 50$$

$$E[L_2] = 1 \cdot 50 = 50$$

Secondo i valori attesi di entrambe le lotterie, non esiste alcun vantaggio nel giocare in una lotteria o nell'altra. Adesso calcoliamo la **varianza** di entrambe le lotterie L_1 ed L_2

$$var(L_1) = E(L_1^2) - E(L_1)^2$$

Calcoliamo $E(L_1^2)$:

$$E(L_1^2) = \frac{1}{4} \cdot (100)^2 + \frac{1}{4} \cdot (200)^2 + \frac{1}{2} \cdot (250)^2 = 2500 + 10000 + 31250 = 43750$$

La varianza di L_1 risulta:

$$var(L_1) = 43750 - 2500 = 41250$$

Calcolare $var(L_2)$ è più semplice, in quanto sia $E(L_2^2)$ che $E(L_2)^2$ sono uguali a $50^2 = 2500$, quindi:

$$var(L_2) = E(L_2^2) - E(L_2)^2 = 2500 - 2500 = 0$$

Quest'ultimo risultato è scontato, in quanto per L_2 era possibile un solo caso con probabilità massima.

Esercizio N.3 - Penitenziario

In un penitenziario dove si trovano 3 prigionieri è annunciato che 2 di loro verranno liberati, senza tuttavia dire chi. Uno dei prigionieri considera la possibilità di chiedere ad un amico secondino l'identità di uno dei prigionieri che sarà liberato (e che non sia lui stesso).

Il prigioniero, tuttavia, esita a porre tale domanda frenato dal seguente ragionamento.

Allo stato attuale la sua probabilità di essere liberato è $\frac{2}{3}$. Chiedendo al secondino (e ottenendo una risposta) la probabilità di essere rilasciato diventerebbe $\frac{1}{2}$, in quanto vi sarebbero due soli prigionieri (uno dei quali è lui stesso) il cui destino è incerto e solo uno di essi verrebbe liberato.

Cosa c'è di sbagliato in questo ragionamento?

Definiamo innanzitutto la notazione:

- Pr - Probabilità
- P_i - Il prigioniero i venga liberato
- G_j - Il secondino dice che verrà liberato P_j

e le probabilità **note**:

1. $Pr[P_1 \wedge P_2] = \frac{1}{3}$
2. $Pr[P_1 \wedge P_3] = \frac{1}{3}$
3. $Pr[P_2 \wedge P_3] = \frac{1}{3}$

Supponiamo che il prigioniero che fa questo ragionamento è il prigioniero 1 e che il secondino gli riveli che verrà liberato il prigioniero 2, indicato con G_2 . Le probabilità che ora abbiamo sono:

1. $Pr[G_2|P_1 \wedge P_2] = 1$
2. $Pr[G_2|P_1 \wedge P_3] = 0$
3. $Pr[G_2|P_2 \wedge P_3] = \frac{1}{2}$

Il prigioniero 1 quindi deve calcolare qual è la probabilità di essere liberato sapendo che G_2 sarà liberato, ovvero:

$$Pr[P_1|G_2] = \frac{Pr[P_1 \wedge G_2]}{Pr[G_2]}$$

Calcoliamo $Pr[P_1 \wedge G_2]$. Esso può essere scritto come:

$$\begin{aligned} Pr[P_1 \wedge G_2] &= Pr[G_2 \wedge P_1] = Pr[G_2 \wedge P_1 \wedge P_2] + Pr[G_2 \wedge P_1 \wedge P_3] = \\ &= Pr[G_2|P_1 \wedge P_2] \cdot Pr[P_1 \wedge P_2] + Pr[G_2|P_1 \wedge P_3] \cdot Pr[P_1 \wedge P_3] = \\ &= 1 \cdot Pr[P_1 \wedge P_2] + 0 \cdot Pr[P_1 \wedge P_3] = 1 \cdot \frac{1}{3} \Rightarrow Pr[P_1 \wedge G_2] = \frac{1}{3} \end{aligned}$$

Adesso calcoliamo $Pr[G_2]$, che può essere scritto come:

$$\begin{aligned} Pr[G_2] &= Pr[G_2 \wedge (P_1 \wedge P_2)] + Pr[G_2 \wedge (P_1 \wedge P_3)] + Pr[G_2 \wedge (P_2 \wedge P_3)] = \\ &= Pr[G_2|P_1 \wedge P_2] \cdot Pr[P_1 \wedge P_2] + Pr[G_2|P_1 \wedge P_3] \cdot Pr[P_1 \wedge P_3] + Pr[G_2|P_2 \wedge P_3] \cdot Pr[P_2 \wedge P_3] = \\ &= 1 \cdot \frac{1}{3} + 0 \cdot \frac{1}{3} + \frac{1}{2} \cdot \frac{1}{3} = \frac{1}{3} + \frac{1}{6} = \frac{3}{6} = \frac{1}{2} \Rightarrow Pr[G_2] = \frac{1}{2} \end{aligned}$$

Quindi la probabilità che P_1 venga rilasciato sapendo che G_2 verrà rilasciato è:

$$Pr[P_1|G_2] = \frac{Pr[P_1 \wedge G_2]}{Pr[G_2]} = \frac{\frac{1}{3}}{\frac{1}{2}} = \frac{2}{3}$$

Esempio N.4 - Dado non truccato

Si supponga di lanciare un dado (non truccato) una volta al secondo, annotando quando esce il 6. Qual è il numero medio di lanci tra un 6 e il successivo?

Possiamo risolvere questo problema con due metodi. Il primo metodo consiste nel definire la variabile aleatoria t , la cui probabilità è:

$$Pr[t] = \left(\frac{5}{6}\right)^{t-1} \cdot \frac{1}{6}$$

Il valore atteso di t è:

$$\begin{aligned} \sum_{t=1}^{\infty} t \cdot Pr[t] &= \sum_{t=1}^{\infty} t \cdot \left(\frac{5}{6}\right)^{t-1} \cdot \frac{1}{6} = \sum_{t=1}^{\infty} [(t-1) \left(\frac{5}{6}\right)^{t-1} \cdot \frac{1}{6} + \left(\frac{5}{6}\right)^{t-1} \cdot \frac{1}{6}] = \\ &= \sum_{t=1}^{\infty} (t-1) \left(\frac{5}{6}\right)^{t-1} \cdot \frac{1}{6} + \frac{1}{6} \sum_{t=1}^{\infty} \left(\frac{5}{6}\right)^{t-1} = \sum_{t=1}^{\infty} (t-1) \left(\frac{5}{6}\right)^{t-1} \cdot \frac{1}{6} + \frac{1}{6} \sum_{i=0}^{\infty} \left(\frac{5}{6}\right)^i = \\ &= \sum_{t=1}^{\infty} (t-1) \left(\frac{5}{6}\right)^{t-1} \cdot \frac{1}{6} + \frac{1}{6} \cdot \frac{1}{1 - \frac{5}{6}} = 1 + \sum_{t=1}^{\infty} (t-1) \left(\frac{5}{6}\right)^{t-1} \cdot \frac{1}{6} = \\ &= 1 + \frac{5}{6} \sum_{t=1}^{\infty} (t-1) \left(\frac{5}{6}\right)^{t-2} \cdot \frac{1}{6} = 1 + \frac{5}{6} \sum_{t=1}^{\infty} t \left(\frac{5}{6}\right)^{t-1} \cdot \frac{1}{6} = \\ &= 1 + \frac{5}{6} E(t) \Rightarrow E(t) = 1 + \frac{5}{6} E(t) \Rightarrow \frac{1}{6} E(t) = 1 \\ &E(t) = 6 \end{aligned}$$

Un metodo alternativo di svolgere questo esercizio è quello di usare un metodo "ricorsivo":

$$\begin{aligned} E(t) &= \frac{5}{6}(1 + E(t)) + \frac{1}{6} \cdot 1 = \frac{5}{6} + \frac{5}{6}E(t) + \frac{1}{6} = 1 + \frac{5}{6}E(t) \\ E(t) &= 1 + \frac{5}{6}E(t) \Rightarrow \frac{1}{6}E(t) = 1 \\ E[t] &= 6 \end{aligned}$$

Capitolo 3

Entropia e Informazione di Shannon

3.1 Informazione di Shannon

L'**Informazione di Shannon** associata a un valore $x \in \mathcal{A}_X$ di una variabile aleatoria X è definita come:

$$h(x) = \log_2 \frac{1}{P[x]}$$

e si misura in **bit**.

3.2 Entropia di una variabile aleatoria

L'entropia (o incertezza) di una variabile aleatoria X è definita come il valore atteso dell'informazione di Shannon.

$$H(X) = \sum_{x \in \mathcal{A}_X} P[x] \log \frac{1}{P[x]} \quad 0 \leq H(X) \leq \log |\mathcal{A}_X|$$

e si misura in **bit**. Inoltre se $P[x] = 0$, accetteremo che $P[x] \log_2 \frac{1}{P[x]} = 0$, ossia, un evento impossibile trasporta informazione nulla.

3.2.1 Proprietà dell'entropia

L'entropia gode di alcune proprietà fondamentali:

1. **Non negatività:** L'entropia di una variabile aleatoria non può essere negativa.

$$H(X) \geq 0$$

Dimostrazione: Si dimostra notando che nella formula dell'entropia:

$$H(X) = \sum_{x \in \mathcal{A}_X} P(x) \log_2 \frac{1}{P(x)}$$

che $\log_2 \frac{1}{P(x)} \geq 0$ in quanto $0 \leq P(x) \leq 1$

2. **Entropia Massima:** L'entropia di una variabile aleatoria è **massima** quando abbiamo una distribuzione **uniforme**, ed è:

$$H(X) \leq \log_2(|\mathcal{A}_x|)$$

3. **Ridondanza:** La ridondanza misura la **differenza** tra $H(X)$ e il suo valore massimo possibile, ovvero $\log_2(|\mathcal{A}_x|)$.

4. **Entropia Congiunta:** L'entropia di due variabili aleatorie X ed Y (dipendenti tra loro) è:

$$H(X, Y) = \sum_{x \in \mathcal{A}_X, y \in \mathcal{A}_Y} P(x, y) \log \frac{1}{P(x, y)}$$

5. **Entropia tra VA indipendenti:** L'entropia tra due variabili aleatorie **indipendenti** consiste nella somma delle entropie delle singole VA:

$$H(X, Y) = H(X) + H(Y)$$

6. **Entropia Condizionata:** L'entropia condizionata di due variabili aleatorie X ed Y descrive quanti bit di informazione sono **necessari**, in media, per descrivere X conoscendo l'informazione acquisita da Y , e si misura così:

$$H(X|Y) = \sum_{x \in A_X, y \in A_Y} P[x, y] \log \frac{1}{P[x|y]}$$

3.2.2 Regola della Catena per l'entropia

La Regola della Catena misura l'entropia totale su due variabili aleatorie X e Y , data dall'entropia di X più l'entropia di Y conoscendo quella di X :

$$H(X, Y) = H(X) + H(Y|X) \quad (3.1)$$

Dimostrazione della Regola della Catena

Si dimostra partendo dalla formula dell'**Entropia Congiunta**:

$$\begin{aligned} H(X, Y) &= \sum_x \sum_y P[x, y] \log_2 \frac{1}{P[x, y]} = \sum_x \sum_y P[x, y] \log_2 \frac{1}{P[y|x]P[x]} = \\ &= \sum_x \sum_y P[x, y] (\log_2 \frac{1}{P[y|x]} + \log_2 \frac{1}{P[x]}) = \sum_{x,y} P[x, y] \log_2 \frac{1}{P[y|x]} + \sum_{x,y} P[x, y] \log_2 \frac{1}{P[x]} \\ H(X, Y) &= \sum_x \sum_y P[x, y] \log \frac{1}{P[x, y]} = \sum_x \sum_y P[x, y] \log \frac{1}{P[y|x]P[x]} = \\ &= \sum_x \sum_y P[x, y] (\log \frac{1}{P[y|x]} + \log \frac{1}{P[x]}) = \sum_{x,y} P[x, y] \log \frac{1}{P[y|x]} + \sum_{x,y} P[x, y] \log \frac{1}{P[x]} \\ H(X, Y) &= \sum_x \sum_y P[x, y] \log \frac{1}{P[x, y]} = \sum_x \sum_y P[x, y] \log \frac{1}{P[y|x]P[x]} = \\ &= \sum_x \sum_y P[x, y] (\log \frac{1}{P[y|x]} + \log \frac{1}{P[x]}) = \sum_{x,y} P[x, y] \log \frac{1}{P[y|x]} + \sum_{x,y} P[x, y] \log \frac{1}{P[x]} \end{aligned}$$

Adesso notiamo che:

$$\sum_{x,y} P[x, y] \log \frac{1}{P[y|x]} = H(Y|X) \quad \text{e} \quad \sum_{x,y} P[x, y] \log \frac{1}{P[x]} = H(X)$$

per cui:

$$H(X, Y) = H(Y|X) + H(X)$$

Esempio N.1 - Entropia

Supponiamo di avere una variabile aleatoria X , con:

- $A_X = \{a, b, c, d, e, f, g, h\}$
- $Pr_x = \{\frac{1}{4}, \frac{1}{8}, \frac{1}{8}, \frac{1}{4}, \frac{1}{32}, \frac{1}{32}, \frac{1}{16}, \frac{1}{8}\}$

dove:

$$Pr[X = a] = \frac{1}{4} \quad ; \quad Pr[X = b] = \frac{1}{8} \quad ; \quad Pr[X = c] = \frac{1}{8} \quad ; \quad \text{etc...}$$

Calcolare l'entropia di X

Per calcolare l'entropia di X applico la formula dell'entropia:

$$H(X) = \sum_{x \in A_X} Pr[X = x] \log_2 \frac{1}{Pr[X = x]}$$

Quindi:

$$\begin{aligned} H(X) &= \frac{1}{4} \cdot \log_2 4 + \frac{1}{8} \cdot \log_2 8 + \frac{1}{8} \cdot \log_2 8 + \frac{1}{4} \cdot \log_2 4 + \frac{1}{32} \cdot \log_2 32 + \frac{1}{32} \cdot \log_2 32 + \frac{1}{16} \cdot \log_2 16 + \frac{1}{8} \cdot \log_2 8 = \\ &= \frac{1}{2} \cdot \log_2 4 + \frac{3}{8} \cdot \log_2 8 + \frac{2}{32} \cdot \log_2 32 + \frac{1}{16} \cdot \log_2 16 = \frac{1}{2} \cdot 2 + \frac{3}{8} \cdot 3 + \frac{1}{16} \cdot 5 + \frac{1}{16} = \\ &= 1 + \frac{9}{8} + \frac{9}{16} = \frac{16 + 18 + 9}{16} = \frac{43}{16} \approx 2,69 \approx 2,7 \end{aligned}$$

Esempio N.2 - Entropia con p uniforme

Supponiamo di avere una variabile aleatoria X , con $A_X = \{a, b, c, d, e, f, g, h\}$ dove

$$\forall x \in A_X \Rightarrow Pr[X = x] = \frac{1}{8}$$

Calcolare l'entropia di X

Uso nuovamente la formula dell'entropia:

$$H(X) = \sum_{x \in A_X} Pr[X = x] \log_2 \frac{1}{Pr[X = x]} = 8 \cdot \frac{1}{8} \cdot \log_2 8 = 3$$

Notiamo inoltre che essendo una distribuzione **uniforme**, l'entropia calcolata è **massima**.

Esempio N.3 - Entropia con evento certo

Supponiamo di avere una variabile aleatoria X , con:

- $A_X = \{a, b, c, d, e, f, g, h\}$
- $Pr_x = \{1, 0, 0, 0, 0, 0, 0, 0\}$

dove:

$$Pr[X = a] = 1 \quad ; \quad Pr[X = b] = 0 \quad ; \quad Pr[X = c] = 0 \quad ; \quad \text{etc...}$$

Calcolare l'entropia di X

Uso nuovamente la formula dell'entropia:

$$H(X) = \sum_{x \in A_X} Pr[X = x] \log_2 \frac{1}{Pr[X = x]} = 1 \cdot \log_2 1 = 0$$

Notiamo che l'entropia in un evento certo è 0, in quanto non può esservi incertezza in un evento sicuro.

3.3 Entropia relativa

Prima di discutere l'entropia relativa, andremo a introdurre dei concetti utili per le nostre dimostrazioni.

3.3.1 Funzioni convesse e disuguaglianza di Jensen

Funzioni Convesse Una funzione $f(x)$ è **convessa** in un intervallo (a, b) se ogni *corda* (segmento) della funzione si trova **sopra** la funzione, ovvero se $\forall x_1, x_2 \in (a, b)$ e $0 \leq \lambda \leq 1$ abbiamo:

$$f(\lambda x_1 + (1 - \lambda)x_2) \leq \lambda f(x_1) + (1 - \lambda)f(x_2) \quad (3.2)$$

Una funzione $f(x)$ è **strettamente convessa** se $\forall x_1, x_2 \in (a, b)$ abbiamo $\lambda = 0$ o $\lambda = 1$

Esempi di funzioni **strettamente convesse** sono:

- x^2 , e^x e e^{-x} per ogni x ;
- $\log(1/x)$ e $x \log x$ per ogni $x > 0$

Disuguaglianza di Jensen Se una funzione $f(x)$ è una funzione **convessa** e x è una variabile aleatoria, allora:

$$E[f(X)] \geq f(E[X]) \quad (3.3)$$

Inoltre se la funzione è **strettamente convessa** e $E[f(X)] = f(E[X])$ allora la variabile aleatoria x è una costante.

La disuguaglianza di Jensen può essere riscritta se la funzione è concava, invertendo il senso.

Dimostrazione:

Dimostriamola per induzione su $|A_x|$:

- **Caso base:** Con $|A_x| = 2$ e x_1, x_2 con $p_1, p_2 = 1 - p_1$ allora:

$$E(f(X)) = p_1 f(x_1) + p_2 f(x_2) = p_1 f(x_1) + (1 - p_1) f(x_2) \geq f(p_1 x_1 + (1 - p_1) x_2) = f(E(X))$$

- **Passo Induttivo:** Essendo la tesi vera per $|A_x| = k$, la dimostriamo per $k + 1$:

$$E[f(X)] = \sum_{i=1}^{k+1} p_i f(x_i) = p_{k+1} f(x_{k+1}) + \sum_{i=1}^k p_i f(x_i) = p_{k+1} f(x_{k+1}) + (1 - p_{k+1}) \sum_{i=1}^k \frac{p_i}{1 - p_{k+1}} f(x_i)$$

Applicando Jensen:

$$\geq p_{k+1} f(x_{k+1}) + (1 - p_{k+1}) f\left(\sum_{i=1}^k \frac{p_i}{1 - p_{k+1}} x_i\right)$$

per la concavità di f :

$$\geq f\left(p_{k+1} x_{k+1} + (1 - p_{k+1}) \sum_{i=1}^k \frac{p_i}{1 - p_{k+1}} x_i\right) = f\left(p_{k+1} x_{k+1} + \sum_{i=1}^k p_i x_i\right) = f\left(\sum_{i=1}^{k+1} p_i x_i\right) = f(E[X])$$

3.3.2 Entropia Relativa (o Divergenza di Kullback-Leibler)

L'entropia relativa tra due distribuzioni di probabilità $P(x)$ e $Q(x)$ definite nello stesso insieme A_X misura l'inefficienza di assumere che la corretta distribuzione sia Q quando invece è P , ed è:

$$D_{KL}(P||Q) = \sum_{x \in A_X} P(x) \log \frac{P(x)}{Q(x)} \quad (3.4)$$

È importante notare che l'Entropia Relativa **non è simmetrica**, quindi:

$$D_{KL}(P||Q) \neq D_{KL}(Q||P)$$

L'entropia relativa soddisfa la **Diseguaglianza di Gibbs**:

$$D_{KL}(P||Q) \geq 0 \quad (3.5)$$

ossia è sempre non negativa. $D_{KL}(P||Q) = 0$ se e solo se $P = Q$

Dimostrazione della Diseguaglianza di Gibbs

$$-D_{KL} = - \sum_{x \in A_X} P(x) \log \frac{P(x)}{Q(x)} = \sum_{x \in A_X} P(x) \log \frac{Q(x)}{P(x)}$$

essendo il logaritmo una funzione concava applichiamo la **disuguaglianza di Jensen**:

$$\leq \log \sum_{x \in A_X} P(x) \frac{Q(x)}{P(x)} = \log \sum_{x \in A_X} Q(x) = \log 1 = 0$$

Invertendo i segni:

$$-D_{KL}(P||Q) \leq 0 \quad \Rightarrow \quad D_{KL}(P||Q) \geq 0$$

3.3.3 Entropia massima

Dopo aver introdotto l'Entropia Relativa e la Diseguaglianza di Gibbs, posso dimostrare che l'entropia massima è:

$$H(X) \leq \log_2 |A_X|$$

Dimostrazione Sia U la distribuzione uniforme:

$$\begin{aligned} D_{KL}(P||U) &= \sum_x P(x) \log \frac{P(x)}{U(x)} = \sum_x P(x) \left(\log P(x) + \log \frac{1}{U(x)} \right) = \\ &= \sum_x P(x) \log P(x) + \sum_x P(x) \log \frac{1}{U(x)} = \end{aligned}$$

Essendo U la distribuzione uniforme $U(x) = \frac{1}{|A_x|}$

$$= - \sum_x P(x) \log \frac{1}{P(x)} + \sum_x P(x) \log \frac{1}{P(x)} = -H(X) + \sum_x P(x) \log |A_x| = -H(X) + \log |A_x|$$

Applicando la disuguaglianza di Gibbs:

$$0 \leq -H(X) + \log |A_x| \quad \Rightarrow \quad H(X) \leq \log |A_x|$$

3.3.4 Mutua Informazione

La Mutua Informazione tra due variabili aleatorie X ed Y misura la perdita media di incertezza su X noto Y , ed è:

$$I(X; Y) = H(X) - H(X|Y) = \sum_{x \in A_X} \sum_{y \in A_Y} P(x, y) \log_2 \frac{P(x, y)}{P(x)P(y)} \quad (3.6)$$




Figura 3.1: Interpretazione grafica di entropia congiunta, condizionata e mutua informazione.

Dimostrazione:

$$\begin{aligned} I(X; Y) &= \sum_{x, y} P(x, y) \log \frac{P(x, y)}{P(x)P(y)} = \sum_{x, y} P(x, y) \log \frac{P(x|y)P(y)}{P(x)P(y)} = \\ &= \sum_{x, y} P(x, y) (\log P(x|y) + \log \frac{1}{P(x)}) = \sum_{x, y} P(x, y) \log \frac{1}{P(x)} + \sum_{x, y} P(x, y) \log P(x|y) \end{aligned}$$

la prima parte per il teorema delle probabilità totali è semplicemente:

$$= H(x) + \sum_{x, y} P(x, y) \log P(x|y) = H(X) - \sum_{x, y} P(x, y) \log \frac{1}{P(x|y)} = H(X) - H(X|Y)$$

3.3.5 Proprietà della Mutua Informazione

La Mutua Informazione comprende diverse proprietà:

1. $I(X; X) = H(X)$ – Dimostrazione: $H(X) - H(X|X) = H(X)$
2. $I(X; Y) = I(Y; X)$
3. $I(X; Y) \geq 0$ – Dimostrazione:

$$\sum_{x \in A_X} \sum_{y \in A_Y} P(x, y) \log_2 \frac{P(x, y)}{P(x)P(y)}$$

poniamo:

$$\hat{P}(x, y) = P(x, y) \quad \text{e} \quad \hat{Q}(x, y) = P(x)P(y)$$

e applichiamo la Diseguaglianza di Gibbs.

Esempio N.4 - Mutua Informazione

Supponiamo di avere le seguenti variabili aleatorie X e Y definite in $A = \{1, 2\}$ e con le seguenti probabilità note:

$$\begin{aligned} Pr[x = 1 \wedge y = 1] &= 0 & Pr[x = 1 \wedge y = 2] &= \frac{1}{8} \\ Pr[x = 2 \wedge y = 1] &= \frac{3}{4} & Pr[x = 2 \wedge y = 2] &= \frac{1}{8} \end{aligned}$$

Calcolare la Mutua Informazione $I(X; Y)$

Per calcolare $I(X; Y)$ devo prima calcolare $H(X)$ e $H(X|Y)$.

Per $H(X)$ devo calcolare $Pr(x)$ che, per il Teorema della Probabilità Totale, diventa:

$$Pr(x) = \sum_y Pr[x \wedge y] = Pr[x \wedge y = 1] + Pr[x \wedge y = 2]$$

Lo divido nei casi $x = 1$ e $x = 2$:

1. $Pr[x = 1] = Pr[x = 1 \wedge y = 1] + Pr[x = 1 \wedge y = 2] = 0 + \frac{1}{8} = \frac{1}{8}$
2. $Pr[x = 2] = Pr[x = 2 \wedge y = 1] + Pr[x = 2 \wedge y = 2] = \frac{3}{4} + \frac{1}{8} = \frac{7}{8}$

Adesso posso trovare $H(X)$:

$$H(X) = \frac{1}{8} \log_2 8 + \frac{7}{8} \log_2 \frac{8}{7} \approx 0,375 + 0,169 = 0,544$$

Per trovare $H(X|Y)$ calcolo prima $H(X|Y = 1)$ e $H(X|Y = 2)$ per poi calcolare:

$$H(X|Y) = Pr[Y = 1] \cdot H(X|Y = 1) + Pr[Y = 2] \cdot H(X|Y = 2)$$

So che $H(X|Y = 1)$ equivale a:

$$\begin{aligned} H(X|Y = 1) &= \sum_x Pr[X = x|Y = 1] \log_2 \frac{1}{Pr[X = x|Y = 1]} = \\ &= Pr[x = 1|y = 1] \log_2 \frac{1}{Pr[x = 1|y = 1]} + Pr[x = 2|y = 1] \log_2 \frac{1}{Pr[x = 2|y = 1]} = \end{aligned}$$

Per il teorema della Probabilità Condizionata:

$$\begin{aligned} Pr[x = 1|y = 1] &= \frac{Pr[x = 1 \wedge y = 1]}{Pr[y = 1]} = 0 & Pr[x = 2|y = 1] &= \frac{Pr[x = 2 \wedge y = 1]}{Pr[y = 1]} = 1 \\ H(X|Y = 1) &= 0 + 0 = 0 \end{aligned}$$

Applico lo stesso ragionamento per $H(X|Y = 2)$:

$$H(X|Y = 2) = Pr[x = 1|y = 2] \log_2 \frac{1}{Pr[x = 1|y = 2]} + Pr[x = 2|y = 2] \log_2 \frac{1}{Pr[x = 2|y = 2]}$$

Calcolo $Pr[y = 2]$:

$$Pr[y = 2] = Pr[y = 2 \wedge x = 1] + Pr[y = 2 \wedge x = 2] = \frac{1}{8} + \frac{1}{8} = \frac{1}{4}$$

Per il teorema della Probabilità Condizionata:

$$\begin{aligned} Pr[x = 1|y = 2] &= \frac{Pr[x = 1 \wedge y = 2]}{Pr[y = 2]} = \frac{1}{8} \cdot 4 = \frac{1}{2} & Pr[x = 2|y = 2] &= \frac{Pr[x = 2 \wedge y = 2]}{Pr[y = 2]} = \frac{1}{8} \cdot 4 = \frac{1}{2} \\ H(X|Y = 2) &= \frac{1}{2} \cdot \log_2 2 + \frac{1}{2} \cdot \log_2 2 = 1 \end{aligned}$$

Quindi $H(X|Y)$ equivale a:

$$H(X|Y) = Pr[Y = 1] \cdot 0 + \frac{1}{4} \cdot 1 = \frac{1}{4}$$

Possiamo infine calcolare $I(X; Y) = H(X) - H(X|Y) = 0,544 - 0,150 = 0,394$

Capitolo 4

Teorema del Codice Sorgente e Compressione

4.1 Massimizzare l'informazione di una variabile aleatoria

Come abbiamo visto nella sezione precedente, l'**Informazione di Shannon** e dell'**Entropia** di una variabile aleatoria X sono essenziali per misurare l'informazione ottenuta e l'incertezza rimanente.

Ma come possiamo **massimizzare** l'informazione ottenuta da una variabile aleatoria? E quanti bit servono per descrivere il risultato di un esperimento?

L'ideale è ottenere una strategia che massimizzi l'informazione ottenuta nel caso medio ad ogni risultato ottenuto da una v.a. e stabilire un limite inferiore di tentativi da realizzare per ottenere l'informazione intera. Definiamo:

- Il **numero** di possibili risultati con $|A_X|$
- Assegniamo un nome **binario** ad ogni risultato
- Il **raw-bit content** di X , ovvero la **dimensione** di ogni nome, è:

$$H_0 = \log_2 |A_X|$$

- Il raw-bit content corrisponde ad un **limite inferiore** per individuare il risultato di X .

Spieghiamo meglio il concetto con degli esempi pratici.

Gioco del 63 (o del 64) Il gioco consiste nell'individuare un intero x compreso tra 0 e 63 (o 1 e 64) nel numero **minore** di "SI" e "NO" possibile. Come possiamo fare?

Prima di individuare la strategia ottima, associamo alle risposte "SI" e "NO" i nomi binari $\{1, 0\}$ e calcoliamo l'**entropia** (raw-bit content). Sapendo che il numero di risultati è **equiprobabile** (distribuzione uniforme), l'entropia calcolata sarà **massima**:

$$H(X) = \log_2 |A_X| = \log_2 64 = 6$$

Supponiamo che l'intero x da indovinare sia 35, una strategia ottima è quella di usare il modulo e le potenze del due:

1. È l'intero $x \geq 32$? SI $\Rightarrow 1$
2. È l'intero $x \bmod 32 \geq 16$? NO $\Rightarrow 0$
3. È l'intero $x \bmod 16 \geq 8$? NO $\Rightarrow 0$
4. È l'intero $x \bmod 8 \geq 4$? NO $\Rightarrow 0$
5. È l'intero $x \bmod 4 \geq 2$? SI $\Rightarrow 1$
6. È l'intero $x \bmod 2 = 1$? SI $\Rightarrow 1$

Formiamo il numero: $100011 \Rightarrow 35$

Questa strategia è coerente con l'Informazione di Shannon, in quanto ad ogni tentativo svolto otteniamo:

$$h(x) = \log_2 \frac{1}{\frac{1}{2}} = \log_2 2 = 1 \text{ bit}$$

Ed essendo 6 i tentativi, al sesto tentativo abbiamo ottenuto 6 bit, ovvero l'entropia.

Abbiamo quindi visto che l'Informazione di Shannon ha senso se i risultati della variabile aleatoria hanno la stessa probabilità. Ma continua ad avere senso se le probabilità ad ogni risultato ottenuto **cambiano**? Vediamo un altro esempio.

Gioco del Sottomarino Nella battaglia navale, ogni giocatore nasconde una flotta di navi in un mare, rappresentato con una matrice 8×8 . Ad ogni turno, un giocatore prova a colpire le navi dell'altro giocatore colpendo uno slot della matrice. Ci sono tre possibili risultati, 'mancato', 'colpito', 'colpito e affondato'.

Per rappresentare l'esempio, semplifichiamo il gioco, dove ogni giocatore ha una sola nave (un sottomarino) di grandezza di un singolo slot. Ci sono quindi solo due possibili risultati:

'colpito', che indichiamo con 'Y' e 'mancato', che indichiamo con 'N'

Essendo $|A_X| = 64$, l'entropia è di 6 bit, come nel gioco precedente.

Tuttavia, rispetto al gioco del 63, nel gioco del Sottomarino non abbiamo una distribuzione di probabilità uniforme, infatti:

Le probabilità al **1° lancio** sono: Le probabilità al **2° lancio** sono: Le probabilità al **3° lancio** sono:

$$P(Y) = \frac{1}{64} \quad ; \quad P(N) = \frac{63}{64} \quad P(Y) = \frac{1}{63} \quad ; \quad P(N) = \frac{62}{63} \quad P(Y) = \frac{1}{62} \quad ; \quad P(N) = \frac{61}{62}$$

E così via.

L'informazione di Shannon ottenuta al primo tentativo, se dovessimo essere fortunati e beccare il sottomarino, sarebbe di 6 bit, ma se invece dovessimo mancarlo sarebbe:

$$h(x) = h_1(N) = \log_2 \frac{64}{63} = 0,0227 \text{ bit}$$

Se mancassimo anche il secondo tentativo, l'Informazione di Shannon ottenuta sarebbe:

$$h_2(N) = \log_2 \frac{63}{62} = 0,0230 \text{ bit}$$

Se mancassimo i primi 32 tentativi, il totale di Informazione di Shannon sarebbe:

$$\log_2 \frac{64}{63} + \log_2 \frac{63}{62} + \dots + \log_2 \frac{33}{32} = 0,0227 + 0,0230 + \dots + 0,0430 = 1 \text{ bit}$$

Perché 1 bit? Perché adesso sappiamo che il sottomarino non si trova in nessuno dei 32 slot provati, che corrispondono al primo tentativo del gioco del 63. Allo stesso modo, dopo 48 tentativi falliti avremo ottenuto in tutto 2 bit di informazione. Se al 49esimo tentativo dovessimo indovinare, otterremo:

$$h_49(Y) = \log_2 \frac{1}{\frac{1}{16}} = \log_2 16 = 4 \text{ bit}$$

che sommati ai 2 bit trovati prima, equivalgono ai 6 bit dell'entropia.

Supponiamo il caso peggiore, ovvero che troviamo il sottomarino al 64esimo tentativo.

Otterremmo ogni bit così:

1. Dopo i primi 32 tentativi otterremo il 1° bit.
2. Dopo 48 tentativi otterremo il 2° bit.
3. Dopo 56 tentativi otterremo il 3° bit.
4. Dopo 60 tentativi otterremo il 4° bit.
5. Dopo 62 tentativi otterremo il 5° bit.
6. Dopo 63 tentativi otterremo il 6° bit. Rimarrà un singolo slot libero, che sarà la posizione del sottomarino.

Possiamo affermare che l'Informazione di Shannon, indipendentemente dalla distribuzione di probabilità, continua ad avere senso per misurare l'informazione ricavata da un evento.

4.2 Introduzione alla compressione

Adesso possiamo discutere di quanti bit sono **necessari** per descrivere il risultato di un evento sorgente. Dimostrare che è possibile comprimere i dati da una particolare sorgente in un file a L bit per simbolo e ricostruire i dati in maniera affidabile equivale a dimostrare che il contenuto di informazione media di quella sorgente è al più L bit per simbolo.

Utilizzeremo le nozioni base del Teorema del Codice Sorgente per la **compressione di una sorgente**. Esistono **due modi** per comprimere una sorgente:

1. **Compressione Lossy**: questo tipo di compressione consente la **perdita di informazione** per comprimere il file sorgente. Un compressore lossy comprime quindi alcuni file ma ne **mappa altri alla stessa codifica**. Denoteremo con δ la probabilità di fallimento del compressore lossy. Se δ può essere ridotto ad un valore molto basso, il compressore può rivelarsi utile.
2. **Compressione Lossless**: questo tipo di compressione **non consente alcun tipo di perdita di informazione**. Un compressore lossless mappa tutti i file a **codifiche diverse**, con la conseguenza che alcuni file potrebbero **ingrandirsi** invece che ridursi. Vogliamo quindi creare un compressore dove la probabilità che un file si ingrandisca sia **molto bassa** e quella in cui si riduca sia **molto elevata**.

4.3 Compressione Lossy

Come possiamo creare una strategia di compressione lossy? Indipendentemente dal tipo di compressore che vogliamo costruire, abbiamo bisogno di conoscere le probabilità di ogni possibile risultato.

Supponiamo di voler comprimere un **file di testo** formato da caratteri ASCII di un alfabeto A_X . In un generico testo in inglese o in italiano con molta probabilità ci sono caratteri **molto utilizzati** e altri invece **molto meno**, che quindi possono essere rimossi dall'alfabeto A_X per creare un alfabeto ridotto A'_X .

Potremmo quindi calcolare il **raw-bit content** degli alfabeti A_X e A'_X per vedere quanto **spazio risparmiamo**. Più caratteri siamo disposti a rimuovere, più la probabilità δ aumenta.

Esempio N.1 - Compressione Lossy di un Alfabeto A_X

Supponiamo di avere un alfabeto A_X formato da questi caratteri e le rispettive probabilità:

$$A_X = \{a, b, c, d, e, f, g, h\} \quad P_X = \left\{ \frac{1}{4}, \frac{1}{4}, \frac{1}{4}, \frac{3}{16}, \frac{1}{64}, \frac{1}{64}, \frac{1}{64}, \frac{1}{64} \right\}$$

Calcoliamo il **raw-bit content** di A_X :

$$H_0(X) = \log_2 8 = 3 \text{ bit}$$

Vogliamo comprimere l'alfabeto A_X eliminando i caratteri poco probabili, ovvero $\{e, f, g, h\}$.

Abbiamo così un alfabeto A'_X formato da $\{a, b, c, d\}$, il cui raw-bit content è $H_0(X') = \log_2 4 = 2$ bit e un $\delta = \frac{1}{16}$.

Per formalizzare una strategia di compressione con un rischio δ , creiamo il più piccolo insieme S_δ affinché la probabilità che x non sia in S_δ è:

$$Pr(x \notin S_\delta) \leq \delta \tag{4.1}$$

4.3.1 Strumenti per la compressione lossy

Definiamo due **strumenti fondamentali** per una compressione lossy ideale:

- **Minimo insieme δ -sufficiente:** Minimo sottoinsieme $S_\delta \subseteq A_X$ tale che:

$$Pr(x \in S_\delta) \geq 1 - \delta \quad (4.2)$$

Questo sottoinsieme S_δ viene costruito in maniera greedy, ordinando gli elementi di A_X in ordine decrescente in base alla loro probabilità ed aggiungendoli ad S_δ partendo da quelli più probabili, fino a quando la probabilità totale è $\geq 1 - \delta$. Possiamo infine assegnare un nome binario ad ogni elemento di S_δ .

- **Essential bit content** di X equivale a:

$$H_\delta(X) = \log_2 |S_\delta| \quad (4.3)$$

ed è la lunghezza delle codifiche di S_δ .

Osservazione: Se $\delta = 0$ l'essential bit content **coincide** con il raw-bit content.

Esempio N.2 - Compressione lossy di blocchi di bit

Supponiamo una variabile aleatoria X che può assumere i valori $x_i \in \{0, 1\}$ con:

- $Pr[x_i = 0] = p_0 = 0.9$
- $Pr[x_i = 1] = p_1 = 0.1$

Supponendo una stringa di 4 bit, a quanto equivale l'**essential bit content** di questa stringa?

Prendiamo in considerazione **i casi possibili**:

1. $Pr[X = 0000] = p_0^4 = 0,6561$
2. $P[X = \text{"x contiene un 1"}] = 4 \cdot (p_0^3 \cdot p_1) = 4 \cdot 0,0729 = 0,3036$
3. $P[X = \text{"x contiene due 1"}] = 6 \cdot (p_0^2 \cdot p_1^2) = 6 \cdot 0,0081 = 0,0486$
4. $P[X = \text{"x contiene tre 1"}] = 4 \cdot (p_0 \cdot p_1^3) = 4 \cdot 0,0009 = 0,0036$
5. $P[X = 1111] = 0,00014$

Essendo $A_X = 16$, calcolo il raw-bit content: $H_0(X) = \log_2 16 = 4$ bit

Di conseguenza, per una compressione lossy efficace, potremmo sicuramente eliminare i casi 4 e 5 e mantenere i casi 1 e 2. Abbiamo due opzioni con il caso 3:

- Se lo mantenissimo, avremmo:

$$Pr[X = \text{"x contiene al massimo due 1"}] > 0,99$$

e un $\delta = 0,01$. Sapendo quindi che $|S_\delta| = 11$ posso calcolare l'essential bit content:

$$H_\delta(X^{11}) = \log_2 11 = 3,45 \text{ bit}$$

Mantenendo il caso 3 ho risparmiato solamente 0,55 bit.

- Se lo rimuovessimo, avremmo:

$$Pr[X = \text{"x contiene al massimo un 1"}] > 0,94$$


e un $\delta = 0,06$. Sapendo quindi che $|S_\delta| = 5$ posso calcolare l'essential bit content:

$$H_\delta(X^5) = \log_2 5 = 2,32 \text{ bit}$$

Rimuovendo il caso 3 ho risparmiato 1,68 bit, un risparmio più consistente, con un δ sempre basso.

Da questo esempio possiamo constatare che $H_\delta(X^N)$ **dipenda troppo** dal parametro δ , un comportamento che dovremmo evitare. Questo tuttavia succede solo con un N **piccolo** infatti, al crescere di N , $H_\delta(X^N)$ diventa sempre meno dipendente da δ .

Possiamo quindi normalizzare rispetto alla lunghezza N di una qualsiasi stringa binaria: $\frac{1}{N}H_\delta(x^N)$



Questo fenomeno è detto **Tipicalità**, cioè al crescere di N la stringa più probabile aumenta il proprio peso e ci si avvicina al comportamento tipico.

4.3.2 Teorema del Codice Sorgente di Shannon

Data una variabile aleatoria X con un'entropia $H(X) = H$ bit, un $\varepsilon > 0$ e $0 < \delta < 1$ allora esiste $N_0 \in \mathbb{N}^+$ tale che, per $N > N_0$ vale:

$$\left| \frac{1}{N}H_\delta(X^N) - H \right| < \varepsilon \quad (4.4)$$

Di conseguenza:

$$H - \varepsilon < \frac{1}{N}H_\delta(X^N) < H + \varepsilon$$

Da questo teorema possiamo dedurre due importanti risultati:

1. Il primo deriva da:

$$\frac{1}{N}H_\delta(X^N) < H + \varepsilon$$

che afferma che anche per δ molto piccoli, il numero di bit per simbolo $\frac{1}{N}H_\delta(X^N)$ necessario per specificare una stringa x con N simboli con probabilità di errore bassa non deve eccedere gli $H + \varepsilon$ bit. Abbiamo bisogno di una **piccola tolleranza** per errore e il numero di bit richiesti crolla da $H_0(X)$ a $(H + \varepsilon)$.

2. Il secondo deriva da:

$$H - \varepsilon < \frac{1}{N}H_\delta(X^N)$$

che afferma che anche se il nostro compressore fosse molto tollerante agli errori di compressione, con un δ vicino a 1, il **numero medio** di bit per simbolo necessari per rappresentare x devono essere almeno $H - \varepsilon$ bit.

Questi due estremi quindi affermano che, indipendentemente dalla nostra tolleranza all'errore, il numero di bit per simbolo necessari per rappresentare x è H bit.

4.4 Compressione lossless

A differenza della compressione lossy, dove i blocchi di codice avevano **lunghezza fissa** e venivano compressi con la **stessa codifica**, nella compressione lossless ogni file ha **lunghezza variabile** e per ogni file vengono usate **codifiche diverse** con la garanzia di comprimere e decomprimere **senza errori**.

L'idea è quella di poter comprimere, in media, assegnando codifiche **più brevi** a simboli/risultati **più probabili** e codifiche **più lunghe** a simboli/risultati **meno probabili**. Questo approccio non è tuttavia esente da difetti:

1. Se alcuni codici simbolici sono accorciati, di quanto gli altri codici potrebbero essere allungati?
2. Come possiamo assicurarci che un codice simbolico sia facile da decodificare?
3. Come possiamo arrivare alla miglior compressione di un codice?

Notazione per gli alfabeti

- A^N denota l'insieme delle N-tuple ordinate di elementi di A . Esempio:

$$\{0, 1\}^3 = \{000, 001, 010, 011, 100, 101, 110, 111\}$$

- A^* denota l'insieme delle stringhe di lunghezza finita su A . Esempio:

$$\{0, 1\}^* = \{0, 1, 00, 01, 10, 11, 000, 001, \dots\}$$

4.4.1 Codici Simbolici

Definizioni di Codice Simbolico e Codice Esteso

Un **codice simbolico** (binario) C di una variabile aleatoria X è una mappatura dei valori $A_X = \{a_1, \dots, a_n\} \rightarrow \{0, 1\}^*$. Denotiamo con $c(x)$ ogni *codeword* che corrisponde ad x e con $l(x)$ denotiamo la **lunghezza** della codifica.

Il **codice esteso** può essere visto come una mappa da $A_X^* \rightarrow \{0, 1\}^*$ ottenuto per **concatenazione** delle codeword corrispondenti (senza punteggiatura):

$$c^* : A_X^* \rightarrow \{0, 1\}^* \quad , \quad c^*(x_1 x_2 \dots x_N) = c(x_1) c(x_2) \dots c(x_N) \quad (4.5)$$

Affinché un codice simbolico sia utile deve rispecchiare tre requisiti:

1. Dev'essere **Univocamente Decodificabile**.
2. Dev'essere facile da decodificare.
3. Dev'essere compresso il più possibile.

Definizione di Codice Univocamente Decodificabile

Un codice simbolico $x(X)$ è **univocamente decodificabile** se il corrispondente codice esteso $C^*(X)$ è tale che non esistano due stringhe distinte con la stessa codifica:

$$\forall x, y \in A_X^* \quad , \quad x \neq y \Rightarrow c^*(x) \neq c^*(y)$$

Esempio N.1 - Codice univocamente decodificabile

Dato un codice simbolico per una variabile aleatoria X definito in:

$A_X = \{a, b, c, d\}$	$P_X = \left\{ \frac{1}{2}, \frac{1}{4}, \frac{1}{8}, \frac{1}{8} \right\}$	<table style="border-collapse: collapse; margin: 0 auto;"> <tr> <th style="border-right: 1px solid black; padding: 2px 5px;">a_i</th> <th style="padding: 2px 5px;">$c(a_i)$</th> <th style="padding: 2px 5px;">l_i</th> </tr> <tr> <td style="border-right: 1px solid black; padding: 2px 5px;">a</td> <td style="padding: 2px 5px;">1000</td> <td style="padding: 2px 5px;">4</td> </tr> <tr> <td style="border-right: 1px solid black; padding: 2px 5px;">b</td> <td style="padding: 2px 5px;">0100</td> <td style="padding: 2px 5px;">4</td> </tr> <tr> <td style="border-right: 1px solid black; padding: 2px 5px;">c</td> <td style="padding: 2px 5px;">0010</td> <td style="padding: 2px 5px;">4</td> </tr> <tr> <td style="border-right: 1px solid black; padding: 2px 5px;">d</td> <td style="padding: 2px 5px;">0001</td> <td style="padding: 2px 5px;">4</td> </tr> </table>	a_i	$c(a_i)$	l_i	a	1000	4	b	0100	4	c	0010	4	d	0001	4
a_i	$c(a_i)$	l_i															
a	1000	4															
b	0100	4															
c	0010	4															
d	0001	4															

Usando il codice esteso, potremmo codificare la stringa **acdbac** come:

$$c^*(acdbac) = 100000100001010010000010.$$

Questa codifica è **univocamente decodificabile**.

OSSERVAZIONE: Un codice simbolico è più semplice da decodificare se è possibile identificarne la fine di una codeword non appena essa si presenta, ciò significherebbe che **nessuna codeword può essere prefisso di un'altra**.

4.4.2 Codici Prefix-free

Una stringa c è **prefisso** di un'altra d se esiste una stringa-coda (o suffisso) s tale che: $cs = d$.
Esempio: 1 e 10 sono entrambi prefisso di 101.


Definizione di Codice Prefix-free

Un codice simbolico è detto **Prefix-free** se nessuna codeword è prefisso di un'altra.


- I codici prefix-free sono anche chiamati **istantanei** o **autopunteggiati**.
- I codici prefix-free sono **univocamente decodificabili**.
- I codici prefix-free sono associati a degli **alberi binari**, che possono essere incompleti se l'albero ha rami non utilizzati e completi se invece ogni ramo è usato.

Esempio N.2 - Codici Prefix-free


1. Il codice $C_1 = \{0, 101\}$ è prefix-free e l'albero che forma è incompleto.



2. Il codice $C_2 = \{1, 101\}$ **non** è prefix-free, tuttavia è univocamente decodificabile.
3. Il codice $C_3 = \{0, 10, 110, 111\}$ è prefix-free e l'albero che forma è completo.



4. Il codice $C_4 = \{00, 01, 10, 11\}$ è prefix-free e l'albero che forma è completo.



Definizione di Lunghezza Attesa

La lunghezza attesa $L(C, X)$ di un codice simbolico C per una variabile aleatoria X è:

$$L(C, X) = \sum_{x \in A_X} P(x) \cdot l(x) = \sum_{i=1}^I p_i \cdot l_i \quad \text{dove } I = |A_X| \quad (4.6)$$

Esempio N.3 - Entropia e Lunghezza Attesa di un codice prefix-free

Dato il codice simbolico C_3 (del precedente esempio) per una variabile aleatoria X definito in:

$A_X = \{\mathbf{a}, \mathbf{b}, \mathbf{c}, \mathbf{d}\} \quad P_X = \left\{ \frac{1}{2}, \frac{1}{4}, \frac{1}{8}, \frac{1}{8} \right\}$	a_i	$c(a_i)$	p_i	$h(p_i)$	$l(a_i)$
	a	0	$\frac{1}{2}$	1	1
	b	10	$\frac{1}{4}$	2	2
	c	110	$\frac{1}{8}$	3	3
	d	111	$\frac{1}{8}$	3	3

Calcoliamo l'entropia e la lunghezza attesa.

$$H(X) = \frac{1}{2} \log_2 2 + \frac{1}{4} \log_2 4 + \frac{1}{8} \log_2 8 + \frac{1}{8} \log_2 8 = \frac{1}{2} + 2 \cdot \frac{1}{4} + 3 \cdot \frac{1}{4} = 1 + \frac{3}{4} = 1.75 \text{ bit}$$

$$L(C_3, X) = \frac{1}{2} \cdot 1 + \frac{1}{4} \cdot 2 + \frac{1}{8} \cdot 3 + \frac{1}{8} \cdot 3 = 1 + \frac{3}{4} = 1.75 \text{ bit}$$

Il codice C_3 è prefix-free e $L(C_3, X) = H(X)$

Esempio N.4 - Entropia e Lunghezza attesa di un codice non univocamente decodificabile

Dato il codice simbolico $C_5 = \{0, 1, 10, 11\}$ per una variabile aleatoria X definito in:

$A_X = \{\mathbf{a}, \mathbf{b}, \mathbf{c}, \mathbf{d}\} \quad P_X = \left\{ \frac{1}{2}, \frac{1}{4}, \frac{1}{8}, \frac{1}{8} \right\}$	a_i	$c(a_i)$	p_i	$h(p_i)$	$l(a_i)$
	a	0	$\frac{1}{2}$	1	1
	b	1	$\frac{1}{4}$	2	1
	c	10	$\frac{1}{8}$	3	2
	d	11	$\frac{1}{8}$	3	2

Calcoliamo l'entropia e la lunghezza attesa.

$$H(X) = 1.75 \text{ bit} \quad L(C_5, X) = \frac{1}{2} \cdot 1 + \frac{1}{4} \cdot 2 + \frac{1}{8} \cdot 2 + \frac{1}{8} \cdot 2 = \frac{1}{2} + \frac{3}{4} = 1.25 \text{ bit}$$

Il codice C_5 non solo non è prefix-free, ma non è nemmeno univocamente decodificabile e $L(C_5, X) < H(X)$

Esempio N.5 - Entropia e Lunghezza attesa di un codice non prefix-free

Dato il codice simbolico $C_6 = \{0, 01, 011, 111\}$ per una variabile aleatoria X definito in:

$A_X = \{\mathbf{a}, \mathbf{b}, \mathbf{c}, \mathbf{d}\} \quad P_X = \left\{ \frac{1}{2}, \frac{1}{4}, \frac{1}{8}, \frac{1}{8} \right\}$	a_i	$c(a_i)$	p_i	$h(p_i)$	$l(a_i)$
	a	0	$\frac{1}{2}$	1	1
	b	01	$\frac{1}{4}$	2	2
	c	011	$\frac{1}{8}$	3	3
	d	111	$\frac{1}{8}$	3	3

Calcoliamo l'entropia e la lunghezza attesa.

$$H(X) = 1.75 \text{ bit} \quad L(C_6, X) = \frac{1}{2} \cdot 1 + \frac{1}{4} \cdot 2 + \frac{1}{8} \cdot 3 + \frac{1}{8} \cdot 3 = 1 + \frac{3}{4} = 1.75 \text{ bit}$$

Il codice C_6 non è prefix-free ma univocamente decodificabile e $L(C_6, X) = H(X)$.

Ma quali sono i limiti imposti dall'univoca decodificabilità?

Data una lista di interi $\{l_i\}$, esiste un codice univocamente decodificabile con lunghezze l_i ?

Possiamo rispondere a queste domande grazie alla **Disuguaglianza di Kraft**

4.4.3 Disuguaglianza di Kraft

Definizione di Disuguaglianza di Kraft

Per ogni codice univocamente decodificabile $C(X)$ sull'alfabeto binario $\{0, 1\}$, le lunghezze delle codeword devono soddisfare:

$$\sum_{i=1}^I 2^{-l_i} \leq 1 \quad \text{dove } I = |A_X| \quad (4.7)$$

Se un codice univocamente decodificabile soddisfa la Disuguaglianza di Kraft con **uguaglianza**, allora si dice che quel codice è **completo**.

Dimostrazione

Definiamo $\sum_{i=1}^I 2^{l_i}$ e sia:

$$S^N = \left[\sum_{i=1}^I 2^{l_i} \right]^N = \sum_{i_1=1}^I \sum_{i_2=1}^I \cdots \sum_{i_N=1}^I 2^{-(l_{i_1} + l_{i_2} + \cdots + l_{i_N})}$$

La quantità dell'esponente, $(l_{i_1} + l_{i_2} + \cdots + l_{i_N})$ è la lunghezza della codifica di una stringa $x = a_{i_1} a_{i_2} \cdots a_{i_N}$ e, per ognuna di tali stringhe, c'è un termine di questa somma.

Introduciamo un array A_l che conta quante stringhe x hanno lunghezza l .

Successivamente definiamo $l_{min} = \min_i l_i$ e $l_{max} = \max_i l_i$ tali che:

$$S^N = \sum_{l=N \cdot l_{min}}^{N \cdot l_{max}} 2^{-l} A_l$$

Poiché il codice C è univocamente decodificabile le codeword sono **tutte distinte** e quindi ci sono al più 2^l stringhe di lunghezza l , con

$$A_l \leq 2^l$$

Allora:

$$S^N = \sum_{l=N \cdot l_{min}}^{N \cdot l_{max}} 2^{-l} A_l \leq \sum_{l=N \cdot l_{min}}^{N \cdot l_{max}} 1 \leq N \cdot l_{max} \quad , \quad \forall N$$

Se S fosse > 1 allora:

$$S^N \leq N \cdot l_{max}$$

il che è un assurdo, in quando S^N ha crescita esponenziale mentre $N \cdot l_{max}$ crescita polinomiale.

Disuguaglianza di Kraft per codici Prefix-free

Dato un insieme di lunghezze che soddisfano:

$$\sum_{i=1}^I 2^{-l_i} \leq 1$$

esiste un codice prefix-free con queste lunghezze delle codeword.

Dimostrazione

Usiamo una strategia greedy. Date le lunghezze $l_1 \leq l_2 \leq \cdots \leq l_I$ consideriamo un albero binario con profondità $l_n = l_{max}$ e $2^{l_{max}}$ foglie. Diremo che un nodo al livello l è disponibile se non è ancora stato scelto né è un discendente di un nodo scelto.

Al passo i :

- Consideriamo un nodo v con profondità $\leq l_i$. Se ha profondità $< l_i$, espandiamolo aggiungendo i suoi figli. Ripetiamo finché non arriviamo a profondità l_i
- Assegniamo v come i -esima codeword. v e i suoi discendenti non sono più disponibili.

Dopo aver assegnato le prime $i - 1$ parole, il peso dei nodi disponibili è:

$$W_i = \sum_v 2^{-\text{depth}(v)} \quad \text{con } v \text{ disponibili}$$

Affermo che $W_i \geq 2^{l_i} \forall i$ e pertanto al passo i esiste almeno un nodo utilizzabile. Dimostriamo questa affermazione per induzione.

Caso Base: All'inizio l'unico nodo disponibile è la radice:

$$W_1 = 2^0 = 1 \geq 2^{l_1} \quad , \quad l_1 \geq 1$$

Passo Induttivo: Supponiamo che l'affermazione sia vero fino al $(i-1)$ -esimo passo.

Al passo i , scegliamo un nodo v a profondità l_i , che contribuisce con 2^{-l_i} al peso. Quindi:

$$W_{i+1} = W_i - 2^{-l_i}$$

Vogliamo

$$W_{i+1} \geq 2^{-l_{i+1}}$$

Dalla disuguaglianza di Kraft applicata a tutti gli n termini

$$\sum_{j=1}^n 2^{-l_j} \leq 1 = W_1 \quad \text{e} \quad W_i = W_1 - \sum_{j=1}^{i-1} 2^{-l_j}$$

quindi

$$W_{i+1} = W_1 - \sum_{j=1}^i 2^{-l_j} \geq \sum_{j=i+1}^n 2^{-l_j} \geq 2^{-l_{i+1}}$$

4.4.4 Quanto possiamo comprimere una sorgente?

Limite inferiore della lunghezza attesa

La lunghezza $L(C, X)$ di un codice C univocamente decodificabile è:

$$L(C, X) \geq H(X) \tag{4.8}$$

Dimostrazione:

Definiamo le *probabilità implicite*:

$$q_i = \frac{2^{-l_i}}{z} \quad \text{con} \quad z = \sum_i 2^{-l_i}$$

affinché:

$$l_i = \frac{\log_2 1}{q_i - \log_2 z}$$

Usiamo quindi la disuguaglianza di Gibbs, per cui diventa:

$$\sum_i p_i \log_2 \frac{1}{q_i} \geq \sum_i p_i \log_2 \frac{1}{p_i} \quad \text{e vale se } q_i = p_i$$

Infine con la disuguaglianza di Kraft con $z \leq 1$:

$$L(C, X) = \sum_i p_i \cdot l_i = \sum_i p_i (\log_2 \frac{1}{q_i} - \log_2 z) \geq \sum_i p_i (\log_2 \frac{1}{p_i} - \log_2 z) \geq H(X)$$

Codice simbolico ottimo

Se la lunghezza attesa è minimizzata ed è uguale all'entropia solo se le lunghezze delle codeword sono uguali all'Informazione di Shannon:

$$l_i = \log_2 \frac{1}{p_i} \quad \text{allora} \quad L(C, X) = H(X)$$

Teorema del Codice Sorgente per Codici Simbolici

Data una variabile aleatoria X esiste un codice prefix-free C la cui lunghezza attesa soddisfa:

$$H(X) \leq L(C, X) \leq H(X) + 1 \quad (4.9)$$

Dimostrazione:

Arrotondiamo per **eccesso** le lunghezze delle codeword rispetto alla loro lunghezza **ottimale**:

$$l_i = \lceil \log_2 \left(\frac{1}{p_i} \right) \rceil$$

Controlliamo che la disuguaglianza di Kraft sia soddisfatta:

$$\sum_{i=1}^I 2^{-l_i} = \sum_{i=1}^I 2^{-\lceil \log_2(\frac{1}{p_i}) \rceil} \leq \sum_{i=1}^I 2^{-\log_2 \frac{1}{p_i}} \leq \sum_{i=1}^I p_i = 1$$

Calcoliamo:

$$H(X) \leq L(C, X) = \sum_{i=1}^I p_i l_i = \sum_{i=1}^I p_i \lceil \log_2 \frac{1}{p_i} \rceil < \sum_i p_i (\log_2 \frac{1}{p_i} + 1) = H(X) + 1$$

OSSERVAZIONE: Se usiamo un codice le cui probabilità sono $\{p_i\}_{i=1}^I$ e usiamo un codice completo con lunghezze l_i , esse ci definiscono le probabilità di un codice ottimale $q_i = 2^{-l_i}$.

La loro lunghezza attesa sarà:

$$L(C, X) = H(X) + \sum_i p_i \log_2 \frac{p_i}{q_i}$$

con $\sum_i p_i \log_2 \frac{p_i}{q_i} = D_{KL}(P||Q)$ (Divergenza di Kullback-Leibler)

4.4.5 Codifica di Huffman

Procedura dell'algoritmo

Dato un set di probabilità P_X , come possiamo trovare un codice prefix-free ottimo?

La codifica di Huffman costruisce un codice prefix-free ottimo che costruisce un **albero binario** dalle sue **foglie**.

1. Si considerano i due simboli meno probabili dell'alfabeto A_X . A questi simboli assegniamo le codeword più lunghe, che avranno **stessa lunghezza** e differiranno soltanto per l'ultima cifra.
2. Combiniamo questi due simboli in un unico simbolo (che ha la somma delle probabilità degli stessi) e ripetiamo.

Visto che ogni passo dell'algoritmo riduce la grandezza dell'alfabeto di uno, esso impiegherà $|A_X| - 1$ passi.

Esempio N.6 - Codifica di Huffman

Supponiamo di avere una variabile aleatoria X con:

$$A_X = \{a, b, c, d, e\} \quad P_X = \{0.25, 0.25, 0.2, 0.15, 0.15\}$$


x	step 1	step 2	step 3	step 4	
a	0.25 —	0.25 —	0.25 — 0	0.55 — 0	1.0
b	0.25 —	0.25 — 0	0.45 —	0.45 — 1	
c	0.2 —	0.2 — 1			
d	0.15 — 0	0.3 —	0.3 — 1		
e	0.15 — 1				

a_i	p_i	$h(p_i)$	l_i	$c(a_i)$
a	0.25	2.0	2	00
b	0.25	2.0	2	10
c	0.2	2.3	2	11
d	0.15	2.7	3	010
e	0.15	2.7	3	011

Calcoliamo l'entropia $H(X)$ e la lunghezza attesa $L(C, X)$

$$H(X) = \frac{1}{4} \log_2 4 + \frac{1}{4} \log_2 4 + \frac{1}{5} \log_2 5 + \frac{3}{20} \log_2 \frac{20}{3} + \frac{3}{20} \log_2 \frac{20}{3} \approx 2,2855 \text{ bit}$$

$$L(C, X) = \frac{1}{4} \cdot 2 + \frac{1}{4} \cdot 2 + \frac{1}{5} \cdot 2 + \frac{3}{20} \cdot 3 + \frac{3}{20} \cdot 3 = 1 + \frac{2}{5} + \frac{9}{10} = \frac{23}{10} = 2,3 \text{ bit}$$



La codifica ottenuta è: $C = \{00, 10, 11, 010, 011\}$

Svantaggi della Codifica di Huffman

La codifica di Huffman produce un codice simbolico ottimo per una variabile aleatoria X , ma non è esente da difetti:

1. **Cambio di variabile aleatoria:** I codici Huffman non possono gestire in modo efficiente il cambio di probabilità di una v.a. e si è costretti a ricreare un nuovo codice di Huffman o ad usare altri approcci **sotto-ottimali**.
2. **Extra-bit:** I codici di Huffman, seppur ottimi, possono produrre un overhead di un extra bit per simbolo. Se l'entropia $H(X)$ è grande, questo overhead è trascurabile, ma se l'entropia $H(X)$ è di un bit per simbolo (o anche minore), l'overhead $L(C, X) - H(X)$ potrebbe dominare la lunghezza del file codificato.

Capitolo 5

Comunicazione su canali Rumorosi

Abbiamo parlato già all'inizio del capitolo di un esempio di canale rumoroso e di alcuni semplici tecniche di rilevamento e correzione degli errori. Essendo i **canali reali rumorosi**, il nostro obiettivo è esaminare se è possibile usare un canale rumoroso per comunicare in modo **affidabile**.

5.1 Canali Rumorosi

Definizione di Canale discreto memoryless Un **canale discreto memoryless** Q è caratterizzato da un alfabeto di **input** A_X , un alfabeto di **output** A_Y e un insieme di distribuzioni di probabilità $Pr[y|x]$, ognuna per ogni $x \in A_X$.

Queste probabilità di transizione possono essere memorizzate in una matrice:

$$Q_{j|i} = Pr[y = b_j | x = a_i] \quad \begin{cases} \text{j-esima riga} \\ \text{i-esima colonna} \end{cases} \quad (5.1)$$

Definizione di capacità di canale

La capacità di un canale Q definisce la massima mutua informazione:


$$C(Q) = \max_{P_X} I(X; Y) \quad (5.2)$$

La distribuzione P_X per cui otteniamo il massimo di $I(X; Y)$ è chiamata **distribuzione input ottimale**.

5.1.1 Esempi di canali rumorosi


Canale Binario Simmetrico:

Dati $A_X = \{0, 1\}$ e $A_Y = \{0, 1\}$ abbiamo:



Z-Channel:


Dati $A_X = \{0, 1\}$ e $A_Y = \{0, 1\}$ abbiamo:



Noisy Typewriter:

Dati $A_X = A_Y = \{A, B, C, \dots, Z, -\}$. Le 27 lettere sono raggruppate in un cerchio e quando il dattilografo (typist) prova a scrivere (ad esempio) B, il risultato può essere A, B o C, con ognuno probabilità $\frac{1}{3}$.


La lettera finale '-' simboleggia la lettera A



$$Pr(y = A|x = B) = \frac{1}{3}$$

$$Pr(y = B|x = B) = \frac{1}{3}$$

$$Pr(y = C|x = B) = \frac{1}{3}$$



Esempio N.1 - Mutua Informazione su Canale Binario Simmetrico

Supponiamo che $f = 0.15$ e che $P_X = \{p_0 = 0.9, p_1 = 0.1\}$. Calcoliamo $I(X; Y)$

Innanzitutto calcoliamo $Pr[y = 0]$ e $Pr[y = 1]$.

$$Pr[y = 0] = Pr[y = 0|x = 0] \cdot Pr[x = 0] + Pr[y = 0|x = 1] \cdot Pr[x = 1] = (1 - f) \cdot p_0 + f \cdot p_1 =$$

$$0.85 \cdot 0.9 + 0.15 \cdot 0.1 = 0.78$$

$$Pr[y = 1] = Pr[y = 1|x = 0] \cdot Pr[x = 0] + Pr[y = 1|x = 1] \cdot Pr[x = 1] = f \cdot (1 - p_0) + (1 - f) \cdot p_1 =$$

$$0.15 \cdot 0.9 + 0.85 \cdot 0.1 = 0.22$$

Per calcolare $I(X; Y) = H(Y) - H(Y|X)$, devo prima calcolare $H(Y)$ e $H(Y|X)$. Cominciamo con $H(Y)$:

$$H(Y) = -Pr[y = 0] \log_2 Pr[y = 0] - Pr[y = 1] \log_2 Pr[y = 1] =$$

$$= (0.78 \cdot \log_2(0.78) + 0.22 \cdot \log_2(0.22)) = H(Pr[y = 1]) = H(0.22) = 0.76$$

Prima di calcolare $H(Y|X)$ dobbiamo ricavare $H(Y|x = 0)$ e $H(Y|x = 1)$. Cominciamo con $H(Y|x = 0)$:

$$H(Y|x = 0) = Pr[y = 0|x = 0] \log_2(Pr[y = 0|x = 0]) + Pr[y = 1|x = 0] \log_2(Pr[y = 1|x = 0]) =$$

$$= (1 - f) \log_2(1 - f) + f \log_2 f = H(f)$$

Adesso calcoliamo $H(Y|x = 1)$:

$$H(Y|x = 1) = Pr[y = 0|x = 1] \log_2(Pr[y = 0|x = 1]) + Pr[y = 1|x = 1] \log_2(Pr[y = 1|x = 1]) =$$

$$= f \log_2 f + (1 - f) \log_2(1 - f) = H(f)$$

Infine calcoliamo $H(Y|X)$:

$$- \sum_{x \in X} \sum_{y \in Y} Pr[X = x, Y = y] \log_2(Pr[Y = y|X = x]) = \sum_{x \in X} Pr[X = x] H(Y|X = x) =$$

$$= p_0 H(Y|x = 0) + p_1 H(Y|x = 1) = 0.9 H(f) + 0.1 H(f) = H(f) = H(0.15) = 0.61$$


Calcoliamo la Mutua Informazione:

$$I(X; Y) = H(0.78) - H(0.61) = 0.76 - 0.61 = 0.15 \text{ bit}$$

Possiamo fare meglio di così? Sì, infatti calcolando la capacità di canale:

$$C(Q_{BSC}) = H(0.5) - H(0.15) = 1.0 - 0.61 = 0.39 \text{ bit}$$

$$I(X; Y)$$



Esempio N.2 - Mutua Informazione su Z-Channel

Supponiamo che $f = 0.15$ e che $P_X = \{p_0 = 0.9, p_1 = 0.1\}$. Dobbiamo ricavare $I(X; Y)$

$$H(Y) = H(\Pr[y = 1]) = H((1 - f) \cdot p_1) = 0.42$$

$$\begin{aligned} \Pr[y = 0] &= \Pr[y = 0|x = 0] \cdot \Pr[x = 0] + \Pr[y = 0|x = 1] \cdot \Pr[x = 1] = \\ &= 0 + (1 - f) \cdot p_1 = 0.85 \cdot 0.1 = 0.085 \end{aligned}$$

Calcoliamo $H(Y|X)$:

$$H(Y|X) = H(Y|x = 0) \Pr[x = 0] + H(Y|x = 1) \Pr[x = 1] =$$


$$H(\Pr[y = 1|x = 0]) p_0 + H(\Pr[y = 1|x = 1]) p_1 = 0 + H(1 - f)p_1 = H(0.85) \cdot 0.1 = 0.61 \cdot 0.1 = 0.061$$

Adesso calcoliamo $I(X; Y)$

$$I(X; Y) = H((1 - f) \cdot p_1) - p_1 \cdot H(1 - f) = 0.42 - 0.061 = 0.36 \text{ bit}$$

Questa funzione in $p_1^* = 0.445$ con $f = 0.15$ non è banale. La capacità di canale $C(Q_Z) = 0.685 \text{ bit}$

$$I(X; Y)$$



Esempio N.3 - Capacità del Noisy Typewriter Channel

Si trova che la distribuzione ottimale input è la distribuzione uniforme che dà:

$$C(Q_{NT}) = \log_2 9 = 3,17 \text{ bit}$$

5.1.2 Teorema del Codice di un Canale Rumoroso

La capacità di canale misura la frequenza di quanti **blocchi di informazione** possono essere trasferiti nel canale con una *piccola quantità di errore arbitraria*.

(N, K) **codici a blocco**

Un (N, K) codice a blocco per un canale Q è una lista di $S = 2^K$ codeword tali che:

$$x^{(1)}, x^{(2)}, \dots, x^{(2^K)}, \quad x^{(s)} \in A_X^N \quad (5.3)$$

ognuna con lunghezza N . Ci permette di codificare $S = 2^K$ segnali usando blocchi di lunghezza N .

OSSERVAZIONE: Il numero di codewords S è un intero, ma il numero di bit necessario per scegliere una codeword, ovvero $K \equiv \log_2 S$, non è necessariamente un intero.

Tasso di comunicazione

Il tasso di comunicazione del codice per canale è:

$$R = \frac{K}{N} \text{ bit} \quad (5.4)$$

OSSERVAZIONE: Questa definizione è usata per qualsiasi canale, tuttavia se il canale non ha un alfabeto di input binario e contiene q simboli, il tasso di comunicazione diventa:

$$R = \frac{K}{N \log_2 q} \text{ bit} \quad (5.5)$$

Decoder per (N, k) codici a blocco

Un decoder per (N, k) codici a blocco mappa da un insieme di stringhe di output S di lunghezza N , ovvero A_Y^N , un segnale

$$\hat{s} \in \{0, 1, 2, \dots, 2^K\}$$

OSSERVAZIONE: Il simbolo $\hat{s} = 0$ può essere usato per indicare un **fallimento**.

Probabilità di un errore di blocco

La **probabilità di un errore di blocco** di un codice e di un decoder, dato un canale e una distribuzione di probabilità sul segnale codificato $P(s_{in})$ è:

$$p_B = \sum_{s_{in}} P(s_{in}) \cdot P(s_{out} \neq s_{in} | s_{in}) \quad (5.6)$$

Probabilità massima di un errore di blocco

La probabilità **massima** di un errore di blocco è:

$$p_{BM} = \max_{s_{in}} P(s_{out} \neq s_{in} | s_{in}) \quad (5.7)$$

Probabilità di errore di bit

Assumendo che s sia rappresentato da un vettore binario $\mathbf{s}$ di lunghezza K , la probabilità di bit error consiste nella probabilità media che un bit dell'output sia diverso dal corrispondente bit dell'input.

$$p_b = \max_s \left(\frac{1}{k} \sum_{i=1}^k Pr[\hat{s}(i) \neq s(i) | s] \right) \quad (5.8)$$

Decoder Ottimale

Il decoder ottimale per un dato canale è quello che minimizza la probabilità di **errore di blocco**. Decodifica un output y come $\hat{s}$ che ha la massima probabilità a posteriori:

$$p[s|y] = \frac{[y|s] \cdot p[s]}{\sum_{s'_{input}} P(y|s') \cdot P(s')} \quad (5.9)$$

con: $s_{output} = \arg\max P(s|y)$

5.1.3 Teorema di Shannon per canali rumorosi

Il Teorema di Shannon si compone di tre parti:

1. Per ogni canale discreto di tipo **memoryless**, la capacità di canale:

$$C = \max_{P_X} I(X; Y) \quad (5.10)$$

ha la seguente proprietà. Per ogni $\varepsilon > 0$, $R < C$ ed N sufficientemente grande, esiste un codice di lunghezza N e tasso $\geq R$ ed un decoder tale che la probabilità di block error massima è $< \varepsilon$.

2. Se si ammette una probabilità di bit error p_b , tassi fino a

$$R(p_b) = \frac{C}{1 - H_2(p_b)} \quad (5.11)$$

sono possibili.

3. Per ogni p_b tassi maggiori di $R(p_b)$ **non sono possibili**.


Conferma del Teorema di Shannon per canali rumorosi sul Noisy Typewriter Channel

Possiamo creare una strategia di comunicazione completamente **priva di errori** usando un codice a blocchi di lunghezza $N = 1$.

Usiamo come alfabeto un sottoinsieme di A_X formato dalle lettere ogni 3: B, E, H, $\dots$, Z

Ognuno di questi simboli può essere **univocamente decodificato** scegliendo la decodifica come il simbolo più vicino di A_X . Questo sottoinsieme d'input ha 9 elementi e il tasso di comunicazione è uguale alla capacità del canale NT:

$$Q(C_{NT}) = \log_2 9$$



Parte II

Informazione Quantistica

Capitolo 6

Fondamenti di algebra lineare

L'algebra lineare è il linguaggio fondamentale della meccanica quantistica, in cui gli stati fisici sono rappresentati come vettori in uno spazio di Hilbert complesso. Operatori hermitiani agiscono su questi vettori per rappresentare osservabili fisiche, mentre le probabilità di misura sono calcolate tramite prodotti scalari, rendendo la teoria quasi interamente formulabile in termini di algebra lineare. Introduciamo quindi i fondamenti di algebra lineare che saranno necessari per la comprensione del corso.

6.1 Spazio di Hilbert e prodotto scalare

Si dice **spazio di Hilbert** uno spazio vettoriale completo rispetto alla norma indotta dal prodotto scalare. Ci saranno utili nello studio dei sistemi quantistici, a causa dell'assioma 1 della meccanica quantistica.

Assioma 1 della meccanica quantistica

Ad ogni sistema fisico quantistico è associato uno spazio di Hilbert $\mathcal{H}$.

Tutti gli spazi di Hilbert che andremo a trattare sono finiti, in quanto i sistemi su cui operiamo sono finiti. Consideriamo lo **spazio di Hilbert** $\mathbb{C}^d$ dei vettori colonna sui numeri complessi. Un elemento di questo spazio di Hilbert, è del tipo

$$\bar{v} = \begin{pmatrix} v_1 \\ v_2 \\ \vdots \\ v_d \end{pmatrix}, \quad v_i \in \mathbb{C}$$

È inoltre dotato del **prodotto scalare** $\langle v|w \rangle = \sum_{i=1}^d \bar{v}_i w_i$. Nel contesto dei numeri complessi, $\bar{v}$ indica il coniugato complesso di v , ossia:

$$v = a + ib, \quad \bar{v} = a - ib$$

Sia $\mathcal{H}$ è uno spazio di Hilbert arbitrario con $\dim(\mathcal{H} = d)$ finita, posso scegliere una **base ortonormale** $\{|e_i\rangle\}_{i=1}^d$ di $\mathcal{H}$, ossia tale che:

$$\langle e_i|e_j \rangle = \begin{cases} 1 & \text{se } i = j \\ 0 & \text{se } i \neq j \end{cases}$$

Indichiamo i vettori di $\mathcal{H}$ con il simbolo $|\psi\rangle$ e $\langle\psi|$ per il suo duale. $|\psi\rangle$ è un vettore colonna, mentre $\langle\psi|$ è un vettore riga.

Base ortonormale standard Una base ortonormale particolare, è la **base ortonormale standard**. La base ortonormale standard di un qualsiasi spazio di Hilbert $\mathcal{H} = \mathbb{C}^d$ è data dall'insieme di vettori

$$|0\rangle = \begin{pmatrix} 1 \\ 0 \\ \vdots \\ 0 \end{pmatrix}, \quad |1\rangle = \begin{pmatrix} 0 \\ 1 \\ \vdots \\ 0 \end{pmatrix}, \dots, \quad |d-1\rangle = \begin{pmatrix} 0 \\ 0 \\ \vdots \\ 1 \end{pmatrix}$$

Se $|\psi\rangle = \begin{pmatrix} \psi_1 \\ \psi_2 \\ \vdots \\ \psi_{d-1} \end{pmatrix}$, allora $|\psi\rangle = \sum_{i=0}^{d-1} \psi_i |i\rangle$, e il suo duale è: $\langle\psi| = (\bar{\psi}_0, \bar{\psi}_1, \dots, \bar{\psi}_{d-1})$.

6.1.1 Disuguaglianza di Schwartz

Il prodotto scalare soddisfa la seguente disuguaglianza, nota come disuguaglianza

$$\forall |\Phi\rangle, |\Psi\rangle \in \mathcal{H} = \mathbb{C}^d, \quad |\langle\Phi|\Psi\rangle|^2 \leq \langle\Phi|\Phi\rangle \cdot \langle\Psi|\Psi\rangle$$

E vale solo se:

$$|\Phi\rangle = k |\Psi\rangle, \exists k \in \mathbb{C}$$

La norma indotta del prodotto scalare è $\|\Psi\| = \sqrt{\langle\Psi|\Psi\rangle}$, per cui possiamo riscrivere il lemma di Schwartz come:

$$\langle\Phi|\Psi\rangle = \|\Phi\| \cdot \|\Psi\|$$

6.2 Mappe lineari e matrici

Utilizziamo funzioni lineari f , con le seguenti proprietà:

1. $f(\lambda x) = \lambda f(x)$,
2. $f(x + y) = f(x) + f(y)$

Dati $\mathcal{H} = \mathbb{C}^d, \mathcal{K} = \mathbb{C}^e$ spazi di Hilbert, $\text{lin}(\mathcal{H}, \mathcal{K})$ è l'insieme delle **mappe lineari** da $\mathcal{H}$ a $\mathcal{K}$.

Se fissiamo una base per $\mathcal{H}$ e una base per $\mathcal{K}$ allora ogni mappa di $\text{lin}(\mathcal{H}, \mathcal{K})$ può essere scritta come una matrice $d \times e$.

Quando la mappa lineare va dallo stesso spazio allo stesso spazio, si dice **endomorfismo**. Un esempio è $\text{lin}(\mathcal{H}, \mathcal{H})$, che indicheremo più brevemente con $\text{lin}(\mathcal{H})$.

Una particolare mappa lineare $\mathcal{H} \rightarrow \mathcal{H}$ è l'identità $\mathbb{1}$.

6.2.1 Traccia

La **Traccia** di $M \in \text{lin}(\mathcal{H})$ si calcola scegliendo una base Σ di $\mathcal{H}$ e sommando gli elementi della diagonale principale.

$$\text{tr}[M] = \sum_{i \in \Sigma} \langle i|M|i\rangle$$

La traccia è un invariante per cambiamenti di base e soddisfa

$$\text{tr}[MN] = \text{tr}[NM], \quad \forall M \in \text{lin}(\mathcal{H}, \mathcal{K}), N \in \text{lin}(\mathcal{K}, \mathcal{H})$$

Se $M \in \text{lin}(\mathcal{H})$ e $N = |\Psi\rangle \langle\Psi|$ per $|\Psi\rangle \in \mathcal{H}$ allora $\text{tr}[MN] = \langle\Psi|M|\Psi\rangle$

6.2.2 Autovettori e autovalori

Se $M \in \text{lin}(\mathcal{H})$ e $\exists |\Psi\rangle \in \mathcal{H}$ non nullo e $\lambda \in \mathbb{C}$ t.c $M|\Psi\rangle = \lambda|\Psi\rangle$ allora $|\Psi\rangle$ è un **Autovettore** di M con **Autovalore** λ .

Se $M \in \text{lin}(\mathcal{H}_1, \mathcal{H}_2)$, dove $\mathcal{H}_1$ ha base Σ_1 e $\mathcal{H}_2$ ha base Σ_2 allora

$$M = \sum_{i \in \Sigma_1} \sum_{j \in \Sigma_2} M_{ij} |i\rangle \langle j| \quad \text{e} \quad M_{ij} = \langle i|M|j\rangle$$

6.2.3 Matrice trasposta coniugata (o aggiunta, o dagger)

Sia $M \in \text{lin}(\mathcal{H}_1, \mathcal{H}_2)$, l'operatore aggiunto di M è $M^\dagger$ (dagger), tale che $M^\dagger = \overline{M}^T$, e che

$$\langle\Psi|M|\Phi\rangle = \overline{\langle\Phi|M^\dagger|\Psi\rangle}$$

Ed inoltre

$$M^\dagger \in \text{lin}(\mathcal{H}_2, \mathcal{H}_1) \quad \text{e} \quad M^\dagger = \sum_{i,j} \overline{M_{ij}} \cdot |j\rangle \langle i|$$

Una proprietà interessante, è che, $\forall M \in \text{lin}(\mathcal{H}_2, \mathcal{H}_3)$, $N \in \text{lin}(\mathcal{H}_1, \mathcal{H}_2)$, vale che $(MN)^\dagger = N^\dagger M^\dagger$.

6.2.4 Operatori Hermitiani

$M \in \text{lin}(\mathcal{H})$ è **Hermitiano** (o autoaggiunto) se $M = M^\dagger$, cioè significa che M ha elementi diagonali M_{ii} reali e $M_{ij} = \overline{M_{ji}}$ per $i \neq j$.

$$\begin{pmatrix} 1 & 1+i \\ 1-i & 0 \end{pmatrix}$$

Le matrici Hermitiane hanno autovalori reali e ammettono una base di autovettori.

6.2.5 Teorema Spettrale

Sia $M \in \text{lin}(\mathcal{H})$ Hermitiana e $\dim(\mathcal{H} = d)$, allora $\exists \lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_d \in \mathbb{R}$ e una base $\{|\Psi\rangle\}_{i=1}^d$ t.c.

$$M = \sum_{i=1}^d \lambda_i |\Psi_i\rangle \langle \Psi_i| \quad \text{e} \quad \{\lambda\}_{i=1}^d \text{ si chiama } \mathbf{Spettro di M}$$

Questo teorema ci dice che una matrice hermitiana può essere diagonalizzata usando matrici unitarie e la matrice diagonale ha elementi reali.

OSS: lo spettro è univocamente determinato da M ma gli autovalori potrebbero essere non unici se lo spettro è degenere.

esempio: $\mathbb{1} = \sum_{i=1}^d |\Psi_i\rangle \langle \Psi_i|$, $\forall \{|\Psi_i\rangle\}_{i=1}^d$

Se M è Hermitiano (o unitario) e f è una funzione a una variabile, allora

$$f(M) = \sum_{i=1}^d f(\lambda_i) |\Psi_i\rangle \langle \Psi_i|$$

Ossia: bisogna che f sia ben definita sullo spettro.

6.2.6 Operatori Positivi

$P \in \text{lin}(\mathcal{H})$ è **Semidefinito positivo** (PSD) oppure solo *positivo* se

$$\forall |\Psi\rangle \in \mathcal{H}, \langle \Psi | P | \Psi \rangle \geq 0$$

$\mathbf{PSD}(\mathcal{H})$ è l'insieme degli operatori $P \geq 0$ su $\mathcal{H}$

$P \in \text{lin}(\mathcal{H})$ è **Definitivo positivo** (PD) $P > 0$ se $\forall \langle \Psi | P | \Psi \rangle > 0$

$PD(\mathcal{H})$ è l'insieme degli operatori $P > 0$ su $\mathcal{H}$

Lemma (caratterizzazione degli operatori PSD):

$P \in \text{lin}(\mathcal{H})$ equivale a dire:

- A. P è PSD , $\langle \Psi | P | \Psi \rangle \geq 0 \quad \forall |\Psi\rangle \in \mathcal{H}$
- B. P è Hermitiano e i suoi autovalori sono **non negativi**
- C. $\exists M \in \text{lin}(\mathcal{H}, \mathcal{K}) : P = M^\dagger M \quad \exists \mathcal{K}$ spazio di Hilbert
- D. $\forall Q \in PSD(\mathcal{H}), \text{tr}[PQ] \geq 0$

Corollario

Se

$$P \in PSD(\mathcal{H}), M \in \text{lin}(\mathcal{H}, \mathcal{K})$$

allora

$$MPM^\dagger \in PSD(\mathcal{K}) \quad P \leq Q \Leftrightarrow Q - P \geq 0$$

Questa nozione induce un ordinamento...

Matrici Unitarie e Isometrie

- $V \in \text{lin}(\mathcal{H}, \mathcal{K})$ è **Isometria** se $V^\dagger V = \mathbb{1}$ (solo se $\dim(\mathcal{H}) \leq \dim(\mathcal{K})$)
- $V \in \text{lin}(\mathcal{H})$ è **Unitaria** se $U^\dagger U = UU^\dagger = \mathbb{1}$

Definiamo $U(\mathcal{H})$ l'insieme delle matrici unitarie su $\mathcal{H}$:

$$\text{Isom}(\mathcal{H}, \mathcal{K})$$

insieme delle matrici isometrie da $\mathcal{H}$ a $\mathcal{K}$

$P \in \text{lin}(\mathcal{H})$ è una **Proiezione** se $P^2 = P$ e P è Hermitiana.

Sia

$$\{|e_i\rangle\}_{i=1}^d$$

base per l'immagine di una proiezione P , allora

$$P = \sum_{i=1}^d |e_i\rangle \langle e_i|$$

Supponiamo M Hermitiana, allora $M = \sum_{i=1}^d \lambda_i |\Psi_i\rangle \langle \Psi_i|$

I proiettori sono $P_\lambda = \sum_{i=\lambda} |\Psi_i\rangle \langle \Psi_i|$

Se $\Lambda =$ insieme degli autovalori distinti, allora

$$M = \sum_{\lambda \in \Lambda} \lambda P_\lambda$$

In generale

$$M \in \text{lin}(\mathcal{H}, \mathcal{K}) \quad , \quad M = \sum_{i=1}^r s_i |e_i\rangle \langle f_i|$$

con $s_i \geq 0$ autovalori, $r = \text{rank}(M)$ ed e_i, f_i basi di $\mathcal{H}$ e $\mathcal{K}$.

6.2.7 Prodotti tensoriali

Def. $\mathcal{H}, \mathcal{K}$ spazi di Hilbert, il loro **Prodotto tensoriale** $\mathcal{H} \otimes \mathcal{K}$ è lo spazio di Hilbert che contiene tutte le combinazioni lineari di vettori della forma $v \otimes u$, $v \in \mathcal{H}, u \in \mathcal{K}$

- $(\alpha v) \otimes (\beta w) = \alpha\beta \cdot v \otimes w, \quad \forall \alpha, \beta \in \mathbb{C}$
- $(v_1 + v_2) \otimes w = v_1 \otimes w + v_2 \otimes w$
- $v \otimes (w_1 + w_2) = v \otimes w_1 + v \otimes w_2$

Il prodotto scalare è definito da

$$\langle v_1 \otimes w_2 | v_2 \otimes w_2 \rangle = \langle v_1 | v_2 \rangle \otimes \langle w_1 | w_2 \rangle$$

Base di $\mathcal{H} \otimes \mathcal{K}$ $\{|i\rangle \otimes |j\rangle\}, |i\rangle \in B_{\mathcal{H}}, |j\rangle \in B_{\mathcal{K}}$

$$|\Phi\rangle |\Psi\rangle = |\Phi\Psi\rangle = |\Phi\rangle \otimes |\Psi\rangle$$

$$|\Phi\rangle^{\otimes n} = |\Phi\rangle \otimes \dots \otimes |\Phi\rangle \quad \mathcal{H}^{\otimes n} = \mathcal{H} \otimes \dots \otimes \mathcal{H}$$

Se $M \in \text{lin}(\mathcal{H}_1, \mathcal{H}_2)$ e $N \in \text{lin}(\mathcal{K}_1, \mathcal{K}_2)$ allora

$$M \otimes N : \mathcal{H}_1 \otimes \mathcal{K}_1 \longrightarrow \mathcal{H}_2 \otimes \mathcal{K}_2$$

$$(M \otimes N)(|\Phi\rangle \otimes |\Psi\rangle) = M|\Phi\rangle \otimes N|\Psi\rangle$$

$$\text{lin}(\mathcal{H}_1 \otimes \mathcal{K}_1, \mathcal{H}_2 \otimes \mathcal{K}_2) = \text{lin}(\mathcal{H}_1, \mathcal{H}_2) \otimes \text{lin}(\mathcal{K}_1, \mathcal{K}_2)$$

$$M = \sum_{i,j} M_{ij} |i\rangle \langle j|, \quad N = \sum_{k,l} N_{kl} |k\rangle \langle l|$$

$$M \otimes N = \sum_{i,j,k,l} M_{ij} N_{kl} |i\rangle \langle j| \otimes |k\rangle \langle l| = \sum_{i,j,k,l} M_{ij} N_{kl} |ik\rangle \langle jl|$$

Lemma 4.1

- $P \in \text{PSD}(\mathcal{H}), Q \in \text{PSD}(\mathcal{K}) \Rightarrow P \otimes Q \in \text{PSD}(\mathcal{H} \otimes \mathcal{K})$
- $\forall M \in \text{lin}(\mathcal{H}), N \in \text{lin}(\mathcal{K}), \text{tr}[M \otimes N] = \text{tr}[M]\text{tr}[N]$
- $\forall M \in \text{lin}(\mathcal{H}), N \in \text{lin}(\mathcal{K}), \text{rank}(M \otimes N) = \text{rank}(M)\text{rank}(N)$
- $|\Phi\rangle \otimes z = z |\Phi\rangle, z \in \mathbb{C} \quad \mathcal{H} \otimes \mathbb{C} = \mathcal{H}$
- $M \otimes |\Psi\rangle : \mathcal{H} \longrightarrow \mathcal{H} \otimes \mathcal{K} \quad (M \otimes |\Psi\rangle) |\Phi\rangle = M|\Phi\rangle \otimes |\Psi\rangle$

$$M \otimes \langle \Psi| : \mathcal{H} \otimes \mathcal{K} \longrightarrow \mathcal{H} \quad (M \otimes \langle \Psi|)(|\Phi\rangle \otimes |\chi\rangle) = \langle \Psi|\chi\rangle M|\Phi\rangle \in \mathcal{H}$$

6.3 Stati Quantistici

$$|0\rangle = \begin{pmatrix} 1 \\ 0 \end{pmatrix} \quad |1\rangle = \begin{pmatrix} 0 \\ 1 \end{pmatrix}$$

$$|q\rangle = \alpha |0\rangle + \beta |1\rangle = \begin{pmatrix} \alpha \\ \beta \end{pmatrix} \quad p(0) = |\alpha|^2, p(1) = |\beta|^2, \quad |\alpha|^2 + |\beta|^2 = 1$$

6.3.1 Spazi di Hilbert

Assioma 1: Ogni sistema quantistico è associato ad uno spazio di Hilbert $\mathcal{H}$.

Se $\dim \mathcal{H} = d$ posso identificare $\mathcal{H}$ come $\mathbb{C}^d$ munito del prodotto scalare standard. Un sistema quantistico associato a $(\mathbb{C}^d, \langle \cdot, \cdot \rangle) = \mathcal{H}$ o può essere pensato come avente d possibili stati distinti.

Esempio: Lo spazio di Hilbert più banale è $\mathbb{C}^2$, associato ad un solo qubit, ed ha come base $|0\rangle$ e $|1\rangle$

6.3.2 Stati Quantistici

Definizione Matrice Densità: una **Matrice densità** è un operatore **semidefinito positivo** $\rho \in PSD(\mathcal{H})$ con traccia $\text{tr}[\rho] = 1$. Denotiamo l'insieme delle matrici densità su $\mathcal{H}$ con

$$S(\mathcal{H}) = \{\rho \in PSD(\mathcal{H}) : \text{tr}[\rho] = 1\}$$

Assioma 2: Lo stato di un sistema quantistico con spazio di Hilbert $\mathcal{H}$ è descritto da una matrice densità.

Stati classici: Sia Ω un insieme di possibili risultati. Allora la collezione delle distribuzioni di probabilità su Ω è:

$$P(\Omega) = \left\{ p : \Omega \rightarrow \mathbb{R}_{\geq 0} \mid \sum_{x \in \Omega} p(x) = 1 \right\}$$

Alcune volte $p_x := p(x)$, inoltre $\{p_x\}_{x \in \Omega}$ è una distribuzione di probabilità.

Sia $\mathcal{H}$ spazio di Hilbert e supponiamo che $\{|x\rangle : x \in \Omega\}$ sia una base di $\mathcal{H}$. Allora possiamo associare ad ogni distribuzione di probabilità $p \in P(\Omega)$ lo stato quantistico

$$\rho = \sum_{x \in \Omega} p(x) |x\rangle \langle x| \in S(\mathcal{H})$$

Esempio: consideriamo la base standard dello spazio di Hilbert a un qubit, $\mathcal{H} = \mathbb{C}^2$ con base $\Omega = \{0, 1\}$

$$\rho = p(0) |0\rangle \langle 0| + p(1) |1\rangle \langle 1| = \begin{pmatrix} p(0) & 0 \\ 0 & p(1) \end{pmatrix}$$

Analogamente, la base di $\mathcal{H} = \mathbb{C}^d$ è data da $\Omega = \{0, 1, \dots, d-1\}$. (Nota: sost. i sigma con omega)

In generale se Ω è un insieme finito, scriviamo $\mathcal{H} = \mathbb{C}^d$ per denotare uno spazio di Hilbert ortonormale $\{|x\rangle : x \in \Omega\}$, i vettori di $\mathcal{H}$ sono combinazioni lineari "formali" dei vettori della base

$$\mathcal{H} = \mathbb{C}^\Omega = \left\{ |v\rangle = \sum_{x \in \Omega} v_x |x\rangle : v_x \in \mathbb{C} \right\}$$

e il prodotto scalare è $\langle v|w\rangle = \sum_{x \in \Omega} \bar{v}_x w_x$

Definizione di Stato Classico: Sia Ω un insieme finito. Uno stato quantistico $\rho \in S(\mathcal{H})$ su $\mathcal{H} = \mathbb{C}^\Omega$ è uno **Stato classico** se nella forma:

$$\rho = \sum_{x \in \Omega} p(x) |x\rangle \langle x|, \quad \text{con } p \in P(\Omega)$$

Esempio: Il lancio di una moneta:

$$\rho = \frac{1}{2} (|0\rangle \langle 0| + |1\rangle \langle 1|) = \frac{1}{2} \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}$$

Gli stati classici sono matrici diagonali rispetto alla base computazionale.

6.3.3 Stati Puri

Dato $|\Psi\rangle \in \mathcal{H}$ con norma unitaria, ovviamente $\| |\Psi\rangle \| = \langle \Psi | \Psi \rangle = 1$, non può essere associato alla matrice densità

$$\rho = |\Psi\rangle \langle \Psi|$$

ρ è una matrice densità, infatti $\rho \in \text{PSD}$ e $\text{tr}[\rho] = \text{tr}[|\Psi\rangle \langle \Psi|] = \text{tr}[\langle \Psi | \Psi \rangle] = 1$

Definizione: uno **Stato puro** $\rho \in S(\mathcal{H})$ è tale se $|\Psi\rangle \in \mathcal{H}$ tale che $\rho = |\Psi\rangle \langle \Psi|$. Uno stato non puro si dice **Stato Misto**.

C'è una ridondanza nella descrizione $|\Psi\rangle$ di uno stato (notazione di Dirac): moltiplicando per una fase globale la matrice densità **non cambia**. Sia $|\Phi\rangle = e^{i\theta} |\Psi\rangle$ con $\theta \in \mathbb{R}$, allora:

$$|\Phi\rangle \langle \Phi| = (e^{i\theta} |\Psi\rangle)(e^{i\theta} \langle \Psi|)^\dagger = e^{i\theta} |\Psi\rangle e^{-i\theta} \langle \Psi| = e^{i\theta-i\theta} |\Psi\rangle \langle \Psi| = |\Psi\rangle \langle \Psi|$$

Lemma 1.3: Sia $\rho \in S(\mathcal{H})$. Le seguenti condizioni sono equivalenti:

- a) ρ è uno stato puro
- b) ρ ha rango 1
- c) ρ è una proiezione

Esempio: In uno stato classico di dimensione 2 **non è puro**, la matrice densità sarà:

$$\begin{pmatrix} \rho & 0 \\ 0 & 1-\rho \end{pmatrix}$$

Nel caso generale, sia $|\psi\rangle = \alpha |0\rangle + \beta |1\rangle$, con $\alpha, \beta \in \mathbb{C}$, $|\alpha|^2 + |\beta|^2 = 1$. Allora:

$$\rho = |\psi\rangle \langle \psi| = \begin{pmatrix} \alpha \\ \beta \end{pmatrix} \begin{pmatrix} \bar{\alpha} & \bar{\beta} \end{pmatrix} = \begin{pmatrix} \alpha^2 & \alpha\bar{\beta} \\ \bar{\alpha}\beta & \beta^2 \end{pmatrix}$$

6.3.4 Stati quantistici generici

Sia $\rho \in S(\mathcal{H}) \Rightarrow \rho \in \text{PSD}(\mathcal{H}) \Rightarrow \rho$ è Hermitiana e i suoi autovalori sono non negativi, vale il

Teorema spettrale:

$$\rho = \sum_{i=1}^d p_i |\psi_i\rangle \langle \psi_i|$$

con $p_i \geq 0$ autovalori e $\{|\psi_i\rangle\}_{i=1}^d$ base di autovettori.

Rispetto a questa base la matrice è diagonale e $\text{tr}[\rho] = \sum_{i=1}^d p_i = 1$

In altre parole gli autovalori $\{p_i\}_{i=1}^d$ definiscono una distribuzione di probabilità: "abbiamo lo stato $|\Phi_i\rangle$ con probabilità p_i ".

Osservazione: Qualunque decomposizione $\rho = \sum_{i=1}^d p_i |\psi_i\rangle \langle \psi_i|$ è simile alla nostra definizione di stato classico. La differenza cruciale è che per uno stato classico la matrice è diagonale rispetto alla base computazionale.

Dato $\mathcal{H}$ di dimensione d possiamo definire lo stato detto **Massimalmente Misto**:

$$\tau_d = \frac{1}{d} \mathbb{1}$$

Questo stato può essere decomposto come:

$$\tau = \sum_{j=1}^d \frac{1}{d} |e_j\rangle \langle e_j| \quad \text{di } \mathcal{H} \quad \{ |e_j\rangle \}_{j=1}^d \text{ base}$$

Ricordiamo che un insieme X si dice **Convesso** se $\forall x_0, x_1 \in X$ e $\forall 0 \leq t \leq 1$,

$$x_t = tx_1 + (1-t)x_0 \in X$$

Questo significa che tutti i punti del segmento tra x_0 e x_1 sono contenuti in X . Chiamiamo x_t una **Combinazione Convessa** di x_0 e x_1 .

I **Punti estremi**, sono quelli che possono essere scritti solo come combinazioni banali ($t = 0$ o $t = 1$).

$P(\Sigma)$ è un insieme convesso che si chiama **Simplesso**. Dato un bit classico, $P(\{0, 1\})$ è un segmento che congiunge $\begin{pmatrix} 1 \\ 0 \end{pmatrix}$ e $\begin{pmatrix} 0 \\ 1 \end{pmatrix}$, che sono due punti estremi.

Lemma 1.6: $S(\mathcal{H}) \subset \text{lin}(\mathcal{H})$ è un insieme convesso e i suoi punti estremi coincidono con l'insieme dei suoi stati puri.

6.4 Qubit e Sfera di Bloch

Le seguenti matrici formano una base dello spazio vettoriale reale delle matrici hermitiane, sono dette **Matrici di Pauli**

$$\mathbb{1} = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}, X = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}, Y = \begin{pmatrix} 0 & -i \\ i & 0 \end{pmatrix}, Z = \begin{pmatrix} 1 & 0 \\ 0 & -1 \end{pmatrix}$$

- X, Y, Z hanno **Traccia 0** (*traceless*)
- Sono hermitiane e unitarie, pertanto $X^2 = Y^2 = Z^2 = \mathbb{1}$
- X, Y, Z hanno **Autovalori 1 e -1**
- X, Y, Z si autocommutano e si semplificano ciclicamente

$$XY = -YX, \quad YZ = -ZY, \quad ZX = -XZ$$

- X, Y, Z si moltiplicano ciclicamente:

$$XY = iZ, \quad YZ = iX, \quad ZX = iY$$

Anche la **traccia dei prodotti** ovviamente è uguale a 0.

Sia $\rho \in \text{lin}(\mathbb{C}^2)$ una matrice hermitiana arbitraria con $\text{tr}[\rho] = 1$

$$\rho = \frac{1}{2}(\mathbb{1} + xX + yY + zZ) = \frac{1}{2} \begin{pmatrix} 1+z & x-iy \\ x+iy & 1-z \end{pmatrix}, \quad \text{con } x, y, z \in \mathbb{R}$$

Siano $\lambda_1, \lambda_2 \in \mathbb{R}$ gli autovalori di ρ , allora $\lambda_1, \lambda_2 \geq 0$ e $\text{tr}[\rho] = 1$ allora almeno uno tra λ_1 e λ_2 deve essere positivo. Quindi, $\rho \in \text{PSD} \Leftrightarrow \lambda_1 \lambda_2 = \det(\rho) \geq 0$

$$\det(\rho) = \frac{1}{4}((1+z)(1-z) - (x-iy)(x+iy)) = \frac{1}{4}(1 - x^2 - y^2 - z^2)$$

$$\begin{aligned} \rho \text{ è PSD} &\Leftrightarrow 1 - x^2 - y^2 - z^2 \geq 0 \Leftrightarrow x^2 + y^2 + z^2 \leq 1 \\ &\Leftrightarrow \vec{r} = (x, y, z) \text{ ha norma } \|\vec{r}\| \leq 1 \end{aligned}$$

Lo stato di un qubit è parametrizzato da una palla solida di raggio 1 ed è chiamata **Palla di Bloch** (*Bloch Ball*), mentre il vettore $\vec{r}$ è chiamata **Vettore di Bloch**.

In che caso otteniamo uno stato puro? La risposta viene data dal Lemma 1.2: se e solo se abbiamo un autovalore uguale a 1 e l'altro uguale a 0, così che $\det(\rho(\vec{r})) = 0$, il che è equivalente al fatto che $\vec{r}$ è unitario. Quindi gli stati puri di un qubit sono parametrizzati da una sfera unitaria su $\mathbb{R}^3$ chiamata **Sfera di Bloch**.

Lemma 2.1: Ogni $\rho \in S(\mathbb{C}^2)$ di un qubit può essere scritto come


$$\rho = \frac{1}{2}(\mathbb{1} + xX + yY + zZ)$$

I punti interni rappresentano stati misti, in particolare il centro $\vec{r} = (0, 0, 0)$ corrisponde allo **Stato massimalmente misto**

$$\rho(\vec{r}) = \tau = \frac{\mathbb{1}}{2}$$

Un vettore $\vec{r} = (0, 0, 2p - 1)$ sull'asse $\vec{z}$ con $p \in [0, 1]$ corrisponde ad uno stato classico

$$\begin{aligned} \rho &= \frac{1}{2}(\mathbb{1} + (2p - 1)Z) = \frac{1}{2} \begin{pmatrix} 1 + (2p - 1) & 0 \\ 0 & 1 - (2p - 1) \end{pmatrix} \\ &= \begin{pmatrix} p & 0 \\ 0 & 1 - p \end{pmatrix} \end{aligned}$$



Vediamo quali stati sono intersezione degli assi con la sfera:

- Asse $\vec{z}$:
 $\vec{r} = (0, 0, 1) = |0\rangle$, $\vec{r} = (0, 0, -1) = |1\rangle$
- Asse $\vec{x}$:
 $\vec{r} = (1, 0, 0) = |+\rangle = \frac{1}{\sqrt{2}}(|0\rangle + |1\rangle)$, $\vec{r} = (-1, 0, 0) = |-\rangle = \frac{1}{\sqrt{2}}(|0\rangle - |1\rangle)$
- Asse $\vec{y}$:
 $\vec{r} = (0, 1, 0) = |+i\rangle = \frac{1}{\sqrt{2}}(|0\rangle + i|1\rangle)$, $\vec{r} = (0, -1, 0) = |-i\rangle = \frac{1}{\sqrt{2}}(|0\rangle - i|1\rangle)$

Abbiamo ottenuto 3 diverse basi di $\mathbb{C}^2$, che chiamiamo basi X, Y, Z

- I vettori della base X sono gli autovettori $|\pm\rangle$ della matrice di Pauli X
- I vettori della base Y sono gli autovettori $|\pm i\rangle$ della matrice di Pauli Y
- I vettori della base Z sono gli autovettori $|0\rangle, |1\rangle$ della matrice di Pauli Z

6.5 Misurazioni

Definizione: una **Misurazione** o **POVM** (*Positive-Operator-Valued-Measure*) su uno spazio di Hilbert $\mathcal{H}$ con insieme dei risultati Ω è una collezione di operatori:

$$\mu = \{\mu(x) \in PSD(\mathcal{H})\}_{x \in \Omega} \quad \text{tale che} \quad \sum_{x \in \Omega} \mu(x) = \mathbb{1}$$

Denotiamo con $Meas(\mathcal{H}, \Omega)$ l'insieme di tutte le misure su $\mathcal{H}$ con l'insieme dei risultati in Ω , inoltre $0 \leq \mu_x \leq \mathbb{1}$ dove $\mu_x = \mu(x)$ (Notazione utilizzata) sono operatori che hanno autovalore

$$\lambda : 0 \leq \lambda \leq 1 \quad \forall x \in \Omega$$

ASSIOMA 3 (Misurazioni)

Quando eseguiamo una misurazione $\mu \in Meas(\mathcal{H}, \Omega)$ su uno stato quantistico $\rho \in S(\mathcal{H})$ osserviamo il risultato $x \in \Omega$ con probabilità

$$p(x) = \text{tr}[\mu_x \rho]$$

Vediamo un esempio: con un singolo qubit consideriamo $\Omega = \{0, 1\}$, e $\mu = \{\mu_0, \mu_1\} : \mu_0 = |0\rangle\langle 0|, \mu_1 = |1\rangle\langle 1|$, che definisce una misurazione. Misuriamo $\rho = |\psi\rangle\langle\psi|$ per $|\psi\rangle = |0\rangle$

$$p(0) = \text{tr}[\mu_0 \rho] = \text{tr}[|0\rangle\langle 0| |0\rangle\langle 0|] = 1$$

$$p(1) = \text{tr}[\mu_1 \rho] = \text{tr}[|1\rangle\langle 1| |0\rangle\langle 0|] = 0$$

se invece $|\psi\rangle = |+\rangle$

$$\begin{aligned} p(0) &= \text{tr}[|0\rangle\langle 0| \frac{1}{2}(|0\rangle + |1\rangle)(\langle 0| + \langle 1|)] = \\ &= \frac{1}{2} \text{tr} \left[\begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix} \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix} \right] = \frac{1}{2} \text{tr} \left[\begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix} \right] = \frac{1}{2} \end{aligned}$$

analogamente $p(1) = \frac{1}{2}$.

Se consideriamo lo stato massimamente misto $\tau = \frac{1}{2}\mathbb{1}$

$$p(0) = \text{tr}[|0\rangle\langle 0| \frac{1}{2}\mathbb{1}] = \frac{1}{2}$$

e analogamente $p(1) = \frac{1}{2}$, cioè dalla misurazione non sappiamo distinguere $|+\rangle$ da τ

6.5.1 Misure rispetto a una base e misure proiettive

Sia $\{|e_x\rangle\}_{x \in \Omega}$ una base arbitraria. Allora possiamo costruire una misurazione con l'insieme dei risultati Ω , definendo

$$\mu_x = |e_x\rangle \langle e_x| \quad \text{per } x \in \Omega$$

Quindi $\sum_{x \in \Omega} \mu_x = \sum_x |e_x\rangle \langle e_x| = \mathbb{1}$ è una misura valida. Questo tipo di misura si chiama misura rispetto ad una base. In particolare, prendendo la base standard $\{|x\rangle\}_{x \in \Sigma}$ otteniamo una misurazione rispetto alla base standard (Σ insieme degli stati classici).

Lemma 3.1 (*Regola di Born*): Dato lo stato quantistico $\rho \in S(\mathcal{H})$, eseguendo una misura rispetto ad una base $\mu_x = |e_x\rangle \langle e_x|$ osserviamo il risultato $x \in \Omega$ con probabilità $p(x) = \langle e_x | \rho | e_x \rangle$. Inoltre se $\rho = |\psi\rangle \langle \psi|$ è uno stato puro $|\psi\rangle = \sum_{x \in \Omega} \Psi_x |e_x\rangle$ allora $p(x) = |\Psi_x|^2$

Dimostrazione: Poichè se $N = |\psi\rangle \langle \psi|$ abbiamo che

$$\text{tr}[MN] = \langle \psi | M | \psi \rangle$$

allora

$$p(x) = \text{tr}[|e_x\rangle \langle e_x| \rho] = \langle e_x | \rho | e_x \rangle$$

Quando

$$\rho = |\psi\rangle \langle \psi|, |\psi\rangle = \sum_{x \in \Omega} \Psi_x |e_x\rangle$$

otteniamo

$$p(x) = \langle e_x | \psi \rangle \langle \psi | e_x \rangle = |\langle \psi | e_x \rangle|^2 = |\Psi_x|^2$$

Un caso più generale avviene quando gli operatori di misura μ_x sono tutte proiezioni, $\mu_x = P_x$. In tal caso abbiamo un operatore di misura proiettiva (*PVM*). $\sum_{x \in \Omega} \mu_x = \mathbb{1}$, le immagini degli μ_x devono essere ortogonali e spannare tutto.

6.5.2 Misurazione di qubit

In generale scegliamo $\vec{r} = (x, y, z)$ con $|\vec{r}| = 1$ e lo stato corrispettivo $-\vec{r}$. Allora

$$\mu_{\vec{r},0} = p(\vec{r}) = \frac{1}{2} \begin{pmatrix} 1+z & x-iy \\ x+iy & 1-z \end{pmatrix}, \quad \mu_{-\vec{r},0} = p(-\vec{r}) = \frac{1}{2} \begin{pmatrix} 1-z & -x+iy \\ -x-iy & 1+z \end{pmatrix}$$

Se eseguiamo questa misura su uno stato quantistico con vettore di Bloch $\vec{s} = (x', y', z')$ allora la probabilità di ottenere 0 è:

$$p(0) = \frac{1}{2} + \frac{1}{2} \vec{r} \cdot \vec{s} = \frac{1}{2} + \frac{1}{2} (xx' + yy' + zz')$$

Geometricamente, $\vec{r} \cdot \vec{s}$ è la proiezione del vettore del Bloch...

Non esiste alcuno stato quantistico per cui entrambe le misure X e Z sono certe. Le misurazioni mappano uno stato quantistico in uno stato classico.

Lemma 3.2: Dato Ω insieme dei risultati classici, $\mathcal{H}$ spazio di Hilbert, supponiamo che per ogni $\rho \in S(\mathcal{H})$ esista una distribuzione di probabilità:

$$P_\rho \in P(\Omega) : p\rho = p_1\rho_1 + p_2\rho_2$$

per ogni stato misto $\rho = p_1\rho_1 + p_2\rho_2$.

Allora, esiste un operatore di misura:

$$\mu : \Omega \rightarrow PSD(\mathcal{H}) : \forall x \in \Omega, p\rho(x) = \text{tr}[\mu(x)\rho]$$

6.6 Sistemi quantistici multipli

Se $\mathcal{H}$ ha una base indicizzata $|x_j\rangle$ da $|x_j\rangle \in \Sigma_j$, allora il prodotto tensoriale $\mathcal{H}_1 \otimes \mathcal{H}_2 \otimes \cdots \otimes \mathcal{H}_n$ ha la base prodotto $|x_1, x_2, \dots, x_n\rangle = |x_1\rangle \otimes |x_2\rangle \otimes \cdots \otimes |x_n\rangle$

ASSIOMA 4 (Sistemi multipli)

Se abbiamo n sistemi quantistici con rispettivi spazi di Hilbert $\mathcal{H}_1, \mathcal{H}_2, \dots, \mathcal{H}_n$, allora il sistema congiunto è associato allo spazio di Hilbert $\mathcal{H}_1 \otimes \mathcal{H}_2 \otimes \cdots \otimes \mathcal{H}_n$

Notazione: A, B, C : Sistemi, $\mathcal{H}_A, \mathcal{H}_B, \mathcal{H}_C$: Spazi associati

$\rho_A, \rho_B, \rho_C, \rho_{AB}, \rho_{BC}, \rho_{AC}, \rho_{ABC}$: Stati congiunti

$\Sigma_A, \Sigma_B, \Sigma_C$: Alfabeti di simboli

$\text{lin}(A) = \text{lin}(\mathcal{H}_A)$, $S(A) = S(\mathcal{H}_A)$, $\text{PSD}(A) = \text{PSD}(\mathcal{H}_A)$

$\mu_A \in \text{Meas}(\mathcal{H}_A, \Omega)$, $\Sigma_{AB} = \Sigma_A \times \Sigma_B$

Definizione: A, B stati quantistici. Gli stati nella forma $\rho = \rho_A \otimes \rho_B$, $\rho_A \in S(A)$, $\rho_B \in S(B)$ si chiama **Stato prodotto**. Uno stato che non è prodotto si dice **Stato correlato**.

Se abbiamo N sistemi, $\rho_{A_1, \dots, A_n} \in S(A_1, \dots, A_n)$ è uno stato prodotto se $\rho_{A_1, \dots, A_n} = \rho_{A_1} \otimes \cdots \otimes \rho_{A_n}$, $\rho_{A_i} \in S(A_i)$

Esempio: Alice e Bob hanno un qubit ciascuno, $\mathcal{H}_A = \mathcal{H}_B = \mathbb{C}^2 \Rightarrow \mathcal{H}_A \otimes \mathcal{H}_B \cong \mathbb{C}^4$

1. Essi potrebbero condividere uno degli stati base: $|00\rangle, |01\rangle, |10\rangle, |11\rangle$, che corrispondono a stati puri e classici;
2. Potrebbero avere $|+\rangle_A |+\rangle_B = \frac{1}{2}(|00\rangle + |01\rangle + |10\rangle + |11\rangle)$, che corrisponde ad uno stato **puro** ma non classico;
3. Uno stato classico **non prodotto** si dice **Massimamente correlato** e corrisponde a 2 bit che si trovano nello stato $|00\rangle$ o $|11\rangle$ con probabilità uniforme:

$$\sigma_{AB} = \frac{1}{2}(|00\rangle\langle 00| + |11\rangle\langle 11|)$$

Esprimendolo nella base $|00\rangle, |01\rangle, |10\rangle, |11\rangle$ otteniamo:

$$\begin{pmatrix} 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 \end{pmatrix}$$

4. Uno stato non classico e non prodotto si dice **Massimamente entangled**

$$|\Phi^+\rangle_{AB} = \frac{1}{\sqrt{2}}(|00\rangle + |11\rangle)$$

$$\begin{aligned} \rho_{AB} &= |\Phi^+\rangle_{AB} \langle \Phi^+|_{AB} = \frac{1}{2}(|00\rangle\langle 00| + |00\rangle\langle 11| + |11\rangle\langle 00| + |11\rangle\langle 11|) = \frac{1}{2} \begin{pmatrix} 1 & 0 & 0 & 1 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 1 & 0 & 0 & 1 \end{pmatrix} = \\ &= \frac{1}{2}(|0\rangle\langle 0| \otimes |0\rangle\langle 0| + |0\rangle\langle 1| \otimes |0\rangle\langle 1| + |1\rangle\langle 0| \otimes |1\rangle\langle 0| + |1\rangle\langle 1| \otimes |1\rangle\langle 1|) \end{aligned}$$

Proprietà:

$$|ab\rangle\langle cd| = (|a\rangle\langle b|)(\langle c| \otimes \langle d|) = |a\rangle\langle c| \otimes |b\rangle\langle d|$$

6.7 Traccia Parziale

Sia $\mu_A = \{\mu_A(x)\}_{x \in \Omega} \in \text{Meas}\{A, \Omega\}$ una misurazione che Alice vuole effettuare sul suo sistema.

Supponiamo che Alice e Bob condividano uno stato quantistico ma non possano comunicare. Esiste un modo per avere solo lo stato ρ_A ?

La maniera più naturale di estendere questa misurazione al sistema AB è considerare la misurazione Globale che esegue μ_A su A e non fa nulla su B :

$$\mu_A \otimes \mathbb{1}_B = \{\mu_A(x) \otimes \mathbb{1}_B : x \in \Omega\}$$

È una misurazione valida?

i $\sum_{x \in \Omega} (\mu_A(x) \otimes \mathbb{1}_B) = (\sum_{x \in \Omega} \mu_A(x)) \otimes \mathbb{1}_B = \mathbb{1}_A \otimes \mathbb{1}_B = \mathbb{1}_{AB}$

ii $\mu_A(x) \otimes \mathbb{1}_B$ è PSD $\forall x \in \Omega$, il loro prodotto è PSD

In generale se Alice e Bob eseguono μ_A e μ_B , rispettivamente con insieme dei risultati Ω_1 e Ω_2 , corrispondono ad una misurazione sul sistema globale

$$\mu_A \otimes \mu_B := \{\mu_A(x) \otimes \mu_B(y) : (x, y) \in \Omega_1 \times \Omega_2\}$$

Si osservi che in tal caso, le sole probabilità dei risultati di Alice non dipendono da quelle dei risultati di Bob

Adesso vogliamo ricostruire una descrizione appropriata dello stato di Alice quando il sistema globale si trova nello stato ρ_{AB} . Vorremmo che:

Capitolo 7

Quantum information processing

7.1 Quantum information processing

Che operazioni possono essere fatti su stati quantistici? Quando si applica un operatore su uno stato quantistico, si effettua una operazione del tipo

$$|\psi\rangle \rightarrow U |\psi\rangle, \quad (7.1)$$

o nel caso delle matrici di densità:

$$|\psi\rangle \langle\psi| \rightarrow U |\psi\rangle \langle\psi| U^\dagger. \quad (7.2)$$

7.1.1 Evoluzione temporale

Lo stato di un sistema quantistico $|\psi_t\rangle$ al tempo t , evolve secondo un Hamiltoniana $H(t)$.

$$\frac{d|\psi_t\rangle}{dt} = -iH(t)|\psi_t\rangle \quad (7.3)$$

Noto lo stato di partenza $|\psi_0\rangle$, otteniamo un'equazione differenziale la cui soluzione determina lo stato $|\psi_0\rangle$ a tutti gli istanti t . La soluzione è tale che $|\psi_t\rangle = U_t |\psi_0\rangle$. Viceversa, data una mappa unitaria $U \in \text{lin}(\mathcal{H})$ esiste una Hamiltoniana $H(t)$ per $H(1) = U$.

Tutte le trasformazioni, in meccanica quantistica, coincidono con operazioni unitarie. In computazione quantistica, questo si traduce in gate ($X, Z, CNOT$).

7.2 Operazioni sugli stati

Queste operazioni sugli stati sono modellate tramite mappe lineari. Vale quindi che

$$\phi_{A \rightarrow B}(\sum_i p_i \rho_i) = \sum_i p_i \phi_{A \rightarrow B}(\rho_i) \quad (7.4)$$

7.2.1 Superoperatori e proprietà

Un superoperatore è un operatore lineare che agisce su altri operatori, mappando operatori lineari ad altri operatori.

Dati i sistemi quantistici A, B , un superoperatore da A a B è una mappa lineare da $\phi_{A \rightarrow B} : \text{Lin}(A) \rightarrow \text{Lin}(B)$. Se $A = B$, usiamo la notazione $\phi_A = \phi_{A \rightarrow A}$.

Alcuni superoperatori, sono:

- **Superoperatore identità**
- **Traccia parziale**
- **Le isometrie**

Inoltre, è possibile comporre superoperatori $A \rightarrow B, B \rightarrow C$ per ottenere un superoperatore $A \rightarrow C$. Inoltre, il prodotto tensoriale $\phi_{A \rightarrow B} \otimes \psi_{C \rightarrow D} = \phi_{AC} \rightarrow \psi_{BD}$.

7.2.2 Mappe positive

Un superoperatore $\phi_{A \rightarrow B}$ è una **mappa positiva** se $\forall P_A \in PSD(A)$ si ha $\phi_{A \rightarrow B} P_A \in PSD(B)$.

Lemma sulla composizione di mappe positive La composizione di mappe positive è una mappa positiva. Questa è la circostanza in cui più gate vengono posti uno dopo l'altro su una linea quantistica.

E sul prodotto tensoriale di mappe positive? Il prodotto tensoriale di mappe positive non è una mappa positiva! Ad esempio, **INSERIRE ESEMPIO DELLA LEZIONE**

Abbiamo quindi bisogno di una condizione più forte, per mantenere la positività, nota come completa positività.

Un superoperatore ... è una mappa completamente positiva (CP) se $\forall$ sistema di riferimento R , il superoperatore $\phi_{A \rightarrow B} \otimes I_R$ è positivo.

$$CP(A, B) = \{\text{superoperatori } CP \text{ da } A \text{ a } B\}, \quad CP(A, A) = \quad (7.5)$$

7.3 Canali quantistici

...

Assioma 5 dell'informazione quantistica

L'insieme delle possibili operazioni da un sistema quantistico A in un altro B è l'insieme dei canali quantistici $C(A, B)$.